UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

Reconstrução virtual de temperaturas a partir de sensores IoT no LASDPC

Gustavo Moura Scarenci de Carvalho Ferreira



São Carlos – SP

Reconstrução virtual de temperaturas a partir de sensores IoT no LASDPC

Gustavo Moura Scarenci de Carvalho Ferreira

Orientador: **Prof. Dr. Júlio Cezar Estrella**

Monografia referente ao projeto de conclusão de curso dentro do escopo da disciplina SSC0670 do Departamento de Sistemas de Computação do Instituto de Ciências Matemáticas e de Computação – ICMC-USP para obtenção do título de Engenheiro de Computação.
Área de Concentração: Sensoriamento virtual e análise de dados de sensores IoT

USP – São Carlos

RESUMO

FERREIRA. **Reconstrução virtual de temperaturas a partir de sensores IoT no LASDPC**. 2026. 48 f. Monografia (Graduação) – Instituto de Ciências Matemáticas e de Computação (ICMC/USP), São Carlos – SP.

Este trabalho avalia a reconstrução virtual de temperaturas com dados históricos de sensores da Internet das Coisas (IoT) no Laboratório de Sistemas Distribuídos e Programação Concorrente (LASDPC), da Universidade de São Paulo. Foram utilizados nove sensores do ambiente 1006, de junho a julho de 2026, com médias de cinco minutos e 12.892 janelas completas. Compararam-se média aritmética, regressão linear e Random Forest, com divisão cronológica de 70% para treinamento e 30% para teste. Os erros absolutos médios entre os nove alvos foram, respectivamente, 0,927 °C, 0,257 °C e 0,254 °C, com vantagens distintas por dispositivo. Na regressão linear com seleção por correlação no treinamento, quatro entradas apresentaram o menor erro médio entre as quantidades avaliadas, de 0,238 °C. Na análise espacial com seis sensores, a correlação apresentou menor erro médio que a proximidade para uma a quatro entradas. O acréscimo de umidade reduziu pouco o erro médio e apresentou efeitos distintos por alvo. Os registros de energia foram limitados a uma auditoria exploratória por sua baixa disponibilidade. Um mapa das médias representou os pontos observados e a divisória, com interpolação ilustrativa fora do cluster. Os resultados sustentam a reconstrução nas condições estudadas, sem assegurar desempenho equivalente em outros períodos ou ambientes.

Palavras-chave: sensoriamento virtual, temperatura, Internet das Coisas, regressão, séries temporais.

LISTA DE ILUSTRAÇÕES

Figura 1 – Distribuição espacial aproximada dos sensores no ambiente do LASDPC. As cores representam os grupos cadastrais 1006, Cluster e Reunião, enquanto os eixos indicam coordenadas relativas. 24
Figura 2 – Visão geral da preparação dos dados, dos experimentos de reconstrução e da avaliação. A análise espacial considera seis sensores com coordenadas conhecidas, e o experimento com umidade utiliza amostras pareadas. A auditoria de energia é independente dos modelos de reconstrução. 26
Figura 3 – Comparação do MAE por sensor-alvo no conjunto de teste. 34
Figura 4 – Reconstrução da temperatura do sensor 891 no conjunto de teste: temperaturas observadas e estimadas (superior) e resíduos das estimativas (inferior). . 35
Figura 5 – Erros por alvo e médias em função da quantidade de entradas. 36
Figura 6 – Desempenho da regressão linear com duas regras de seleção. 38
Figura 7 – Temperaturas médias observadas e interpolação IDW ilustrativa. 39
Figura 8 – Séries de umidade e disponibilidade das janelas no período. 40
Figura 9 – MAE da regressão linear com e sem umidade dos sensores de entrada. . . . 41
Figura 10 – Campo de energia e temperaturas no curto intervalo disponível. 42

LISTA DE TABELAS

Tabela 1 – Síntese dos principais trabalhos relacionados e suas contribuições para o presente estudo. 20
Tabela 2 – Disponibilidade e estatísticas das médias de cinco minutos. 32
Tabela 3 – Médias das métricas entre os nove sensores-alvo no teste. 33
Tabela 4 – MAE por sensor-alvo e método, em graus Celsius. 34
Tabela 5 – Médias das métricas da regressão linear por quantidade de entradas. 35
Tabela 6 – Coordenadas relativas e médias nas 12.892 janelas comuns. 37
Tabela 7 – Seleção por correlação e proximidade: médias entre seis alvos (°C). 37
Tabela 8 – Disponibilidade e estatísticas da umidade relativa agregada. 39
Tabela 9 – Regressão linear com e sem umidade, nas mesmas amostras por alvo. 40
Tabela 10 – Efeito da umidade no MAE por alvo; diferença negativa indica redução. . . 41

SUMÁRIO

1 INTRODUÇÃO 11
1.1 Contextualização e Motivação 11
1.2 Delimitação e Evolução do Escopo 12
1.3 Objetivos 13
1.4 Organização do Trabalho 13

2 REVISÃO BIBLIOGRÁFICA 15
2.1 Considerações Iniciais 15
2.2 Conceitos e Técnicas Relevantes 15
2.2.1 Monitoramento Ambiental e Internet das Coisas *15*
2.2.2 Séries Temporais e Pré-processamento de Dados *15*
2.2.3 Aprendizado de Máquina e Enriquecimento dos Dados *16*
2.2.4 Sensoriamento Virtual de Temperatura *16*
2.2.5 Métodos de Estimativa e Avaliação *17*
2.2.6 Relação com o Conforto Térmico *18*
2.3 Trabalhos Relacionados 18
2.4 Considerações Finais 20

3 DESENVOLVIMENTO DO TRABALHO 23
3.1 Considerações Iniciais 23
3.2 Descrição do Problema e do Ambiente 23
3.2.1 Problema de reconstrução *23*
3.2.2 Ambiente experimental e cadastro *24*
3.2.3 Infraestrutura de monitoramento e armazenamento *25*
3.3 Descrição das Atividades Realizadas 25
3.3.1 Operacionalização do Enriquecimento *27*
3.3.2 Delimitação do conjunto experimental *27*
3.3.3 Agregação, sincronização e valores ausentes *27*
3.3.4 Métodos de reconstrução *28*
3.3.5 Protocolo temporal e métricas *28*
3.3.6 Quantidade e seleção de sensores de entrada *29*
3.3.7 Análise espacial complementar e mapa térmico *29*
3.3.8 Umidade como informação complementar *30*

3.3.9 *Auditoria exploratória do campo de energia* *31*
3.3.10 *Organização e rastreabilidade* *32*
3.4 Resultados Obtidos 32
3.4.1 *Caracterização dos dados* *32*
3.4.2 *Comparação entre métodos* *33*
3.4.3 *Diferenças entre sensores-alvo* *33*
3.4.4 *Influência da quantidade de entradas* *35*
3.4.5 *Disponibilidade dos dados nas fontes consultadas* *36*
3.4.6 *Coordenadas e comparação da seleção espacial* *37*
3.4.7 *Distribuição espacial das temperaturas médias* *38*
3.4.8 *Caracterização da umidade e efeito do enriquecimento* *38*
3.4.9 *Disponibilidade e interpretação dos registros de energia* *41*
3.4.10 *Síntese e alcance dos resultados* *42*
3.5 Dificuldades e Limitações 44
3.6 Considerações Finais 44

4 CONCLUSÃO 45

REFERÊNCIAS 47

Capítulo 1

INTRODUÇÃO

1.1 Contextualização e Motivação

O monitoramento de condições ambientais em espaços internos desempenha um papel importante na caracterização e no acompanhamento das condições de funcionamento desses ambientes. Entre as variáveis frequentemente monitoradas, a temperatura se destaca por sua relação com o conforto térmico, com o funcionamento de equipamentos e com as condições de operação de determinados espaços. Nesse contexto, a utilização de dispositivos conectados à Internet das Coisas (Internet of Things — IoT) permite realizar medições periódicas e armazenar grandes volumes de dados para posterior análise.

Sistemas de monitoramento baseados em sensores distribuídos possibilitam acompanhar a evolução temporal da temperatura em diferentes posições de um ambiente. Entretanto, as medições obtidas por esses dispositivos representam apenas as condições observadas em seus respectivos pontos de instalação. A distribuição espacial da temperatura pode não ser uniforme, especialmente em ambientes que apresentam equipamentos eletrônicos, sistemas de climatização, divisórias e diferentes condições de circulação de ar. Dessa forma, a temperatura registrada em um determinado ponto não necessariamente representa a temperatura de todo o espaço monitorado.

Uma alternativa para ampliar o aproveitamento das informações disponíveis é o emprego de técnicas de sensoriamento virtual, como discutido por Brunello *et al.* (2021). Diferentemente de um sensor físico, que realiza diretamente a medição de uma grandeza, um sensor virtual utiliza informações provenientes de outras fontes para estimar o valor dessa grandeza. No monitoramento térmico, essa abordagem permite investigar a possibilidade de estimar a temperatura em uma determinada posição a partir das medições realizadas por sensores instalados em outras posições.

A viabilidade dessa abordagem depende, entre outros fatores, das relações existentes entre as séries temporais dos sensores, da distribuição espacial dos dispositivos e do método utilizado para realizar as estimativas. Sensores próximos podem apresentar comportamentos semelhantes, mas essa relação não é necessariamente determinada apenas pela distância física. Características específicas do ambiente também podem influenciar as medições e, consequentemente, a precisão das estimativas.

Nesse cenário, métodos estatísticos e de aprendizado de máquina podem ser empregados para identificar relações entre as temperaturas registradas por diferentes dispositivos. Modelos como regressão linear e Random Forest permitem construir estimativas a partir de observações históricas, oferecendo alternativas a estratégias mais simples, como o cálculo da média das temperaturas dos sensores disponíveis.

O presente trabalho investiga a reconstrução virtual de medições de temperatura utilizando dados históricos de sensores IoT instalados em ambientes internos de laboratório. O estudo considera uma infraestrutura de monitoramento já existente, sem alterações no posicionamento físico dos dispositivos. Dessa forma, a investigação concentra-se no aproveitamento dos dados disponíveis e na avaliação de diferentes estratégias de estimativa.

Para possibilitar a avaliação quantitativa dos métodos, adota-se uma abordagem na qual as medições de um sensor físico são utilizadas como referência, enquanto as medições dos demais sensores servem como entradas para os modelos. Assim, é possível comparar as temperaturas estimadas com os valores efetivamente registrados e quantificar os erros de reconstrução.

Além da comparação entre diferentes modelos, o trabalho busca investigar como a quantidade de sensores utilizados e os critérios empregados para sua seleção influenciam a qualidade das estimativas. Para isso, são consideradas tanto as relações estatísticas entre as séries temporais quanto as informações aproximadas sobre a localização física dos dispositivos.

1.2 Delimitação e Evolução do Escopo

A proposta inicial, intitulada *Enriquecimento de Dados de Sensores IoT para Aprendizado de Máquina focado em Conforto Térmico no LASDPC*, previa estruturar os históricos e associá-los à localização física, aos estados da climatização e a outras informações para apoiar modelos de estimativa térmica e inferência de conforto. O presente documento explicita o recorte efetivamente executado: a reconstrução de temperaturas registradas por sensores físicos, com referência observada para avaliação.

A preparação dos dados resultou em matrizes temporais sincronizadas. O enriquecimento foi operacionalizado pela associação dos identificadores ao cadastro e às coordenadas, e pela integração da umidade às entradas dos modelos. A regressão linear e a Random Forest constituem as abordagens de aprendizado supervisionado avaliadas. As coordenadas apoiam a seleção por proximidade e a representação espacial; não foram adicionadas como variáveis explicativas dos modelos individuais de cada alvo.

O conforto térmico permanece como motivação e possibilidade de aplicação. Não foram coletadas todas as variáveis necessárias a uma avaliação de conforto, nem respostas dos ocupantes que permitissem validá-la. Também não foram integradas informações meteorológicas externas ou estados confirmados dos aparelhos de climatização. Os registros de energia foram limitados a

uma auditoria, devido à curta disponibilidade e à unidade não confirmada do campo consultado.

Assim, a contribuição apresentada está na estruturação, no enriquecimento e na avaliação dos dados para sensoriamento virtual. O mapa permite visualizar diferenças entre temperaturas médias em posições conhecidas, mas não representa a validação de um gradiente térmico contínuo ou de condições de conforto. A inferência de conforto e o controle automatizado, previstos como aplicações na proposta inicial, dependem de uma etapa adicional de instrumentação e definição do protocolo de avaliação.

1.3 Objetivos

No recorte delimitado, o objetivo geral é avaliar a reconstrução virtual de temperaturas a partir de dados históricos de sensores IoT, estruturados e enriquecidos com cadastro espacial e umidade, utilizando medições físicas como referência experimental.

Como objetivos específicos, estabelecem-se:

- caracterizar os dados históricos e a disponibilidade das medições;
- organizar os sensores por identificadores cadastrais e posições relativas;
- preparar e sincronizar as séries em uma grade temporal comum;
- comparar média aritmética, regressão linear e Random Forest;
- investigar o efeito da quantidade de sensores de entrada;
- comparar seleção por correlação e proximidade no subconjunto com coordenadas;
- avaliar a umidade dos sensores de entrada como informação complementar à reconstrução de temperatura;
- interpretar os erros por sensor e representar espacialmente as temperaturas médias.

1.4 Organização do Trabalho

Este trabalho está organizado em quatro capítulos. O Capítulo 2 apresenta os conceitos de sensoriamento virtual, séries temporais e métodos de estimativa, além dos trabalhos relacionados. O Capítulo 3 descreve a infraestrutura, os dados, o pré-processamento e o protocolo de avaliação, e apresenta os resultados e suas limitações. O Capítulo 4 reúne as conclusões e as possibilidades de continuidade da pesquisa.

Capítulo 2

REVISÃO BIBLIOGRÁFICA

2.1 Considerações Iniciais

A reconstrução de temperaturas a partir de redes de sensores envolve relações entre as medições, disponibilidade dos registros e escolha das entradas. Este capítulo apresenta os conceitos de monitoramento IoT, séries temporais e sensoriamento virtual, seguidos dos métodos de estimativa e das pesquisas que fundamentam a avaliação experimental.

2.2 Conceitos e Técnicas Relevantes

2.2.1 Monitoramento Ambiental e Internet das Coisas

A Internet das Coisas (*Internet of Things* – IoT) integra dispositivos de aquisição, comunicação e serviços que disponibilizam medições para acompanhamento e análise. Em aplicações ambientais, sensores distribuídos registram grandezas como temperatura e umidade, produzindo séries associadas a diferentes posições físicas.

Marques *et al.* (2026) descrevem uma infraestrutura de laboratório com dispositivos ESP32, comunicação multiprotocolo e armazenamento de séries temporais. A disponibilidade de históricos dessa infraestrutura permite investigar o aproveitamento conjunto das medições, além do monitoramento direto de cada dispositivo. Contudo, a presença de um registro no banco não assegura continuidade, sincronização ou representatividade de todas as posições do ambiente.

2.2.2 Séries Temporais e Pré-processamento de Dados

Uma série temporal reúne observações associadas a instantes ou intervalos de tempo. Sensores podem registrar valores em instantes diferentes e apresentar lacunas, mesmo quando possuem frequências nominais semelhantes. A análise conjunta exige verificar identificadores, convenções temporais, duplicatas, valores inválidos e disponibilidade simultânea.

Uma estratégia de sincronização é agregar as medições em intervalos regulares. Para o sensor s e a janela t, a média é

$$\overline{T}_{s,t} = \frac{1}{n_{s,t}} \sum_{j=1}^{n_{s,t}} T_{s,t,j}, \tag{2.1}$$

em que $n_{s,t} > 0$ é a quantidade de medições disponíveis e $T_{s,t,j}$ a j-ésima temperatura da janela. Intervalos maiores reduzem a resolução temporal e podem facilitar a coincidência dos registros, enquanto intervalos menores preservam variações mais rápidas.

Valores ausentes podem ser preservados, excluídos ou imputados, conforme o objetivo e as características dos dados. AlSalehy e Bailey (2025) discutem a importância de considerar a estrutura temporal na detecção de anomalias e no preenchimento de lacunas ambientais. Qualquer regra adotada deve ser documentada para permitir interpretar suas consequências sobre o conjunto efetivamente avaliado.

2.2.3 Aprendizado de Máquina e Enriquecimento dos Dados

O aprendizado de máquina é a abordagem de inteligência artificial (IA) empregada neste estudo. No aprendizado supervisionado, observações históricas relacionam variáveis de entrada a uma resposta conhecida, permitindo ajustar um modelo e avaliar suas estimativas em outras observações. Para a implementação dos modelos supervisionados, foi utilizada a biblioteca Scikit-learn (PEDREGOSA *et al.*, 2011), especificamente as classes `LinearRegression` e `RandomForestRegressor`, empregadas, respectivamente, na regressão linear e na regressão por florestas aleatórias (BREIMAN, 2001).

O enriquecimento amplia as informações associadas aos registros. No contexto deste trabalho, compreende vincular as medições a metadados dos dispositivos e às posições físicas, além de combinar temperatura e umidade em uma mesma janela temporal. As informações espaciais podem orientar a seleção de entradas, enquanto a inclusão de outra grandeza ambiental permite investigar sua contribuição preditiva. O benefício precisa ser demonstrado na avaliação, pois aumentar as informações não assegura menor erro.

A integração de grandezas ambientais e registros de energia também é explorada por Tavoni *et al.* (2026), que utilizam essas informações na previsão de consumo em uma arquitetura de gêmeo digital. A combinação de diferentes variáveis permite considerar múltiplos aspectos das condições ambientais, oferecendo informações adicionais aos modelos de aprendizado de máquina. Essa abordagem se relaciona ao enriquecimento investigado neste trabalho, no qual as medições de umidade são incorporadas às temperaturas dos sensores para avaliar sua contribuição na reconstrução térmica. Embora os estudos apresentem objetivos distintos, ambos investigam o aproveitamento conjunto de diferentes fontes de informação.

2.2.4 Sensoriamento Virtual de Temperatura

Um sensor virtual utiliza informações disponíveis para estimar uma grandeza que poderia ser medida por um sensor físico. Na reconstrução de temperaturas, o problema pode ser representado por

$$\widehat{T}_p(t) = f\big(T_1(t), \ldots, T_k(t)\big), \tag{2.2}$$

em que p é o alvo, k é a quantidade de entradas e f é o método de estimativa. As medições do próprio alvo não podem integrar essas entradas durante a reconstrução; seu histórico pode fornecer a resposta para treinamento supervisionado. Neste trabalho, o sensoriamento virtual é avaliado por meio da reconstrução das medições de sensores físicos existentes, tratados individualmente como alvos de estimativa. Esse procedimento permite comparar os valores reconstruídos com medições reais, sem depender de observações em posições não instrumentadas.

Brunello *et al.* (2021) constitui uma das referências metodológicas deste trabalho, especialmente pela investigação da reconstrução de temperaturas a partir de outros sensores e pela avaliação da influência da seleção das entradas. Essas questões orientaram os experimentos realizados no LASDPC, nos quais foram comparados diferentes métodos de estimativa e critérios de seleção de sensores, considerando uma infraestrutura física previamente instalada. A distância física e a correlação entre séries são critérios distintos: o primeiro utiliza coordenadas, enquanto o segundo expressa associação entre observações. Mais entradas podem adicionar informação ou redundância, tornando necessário avaliar seu efeito em dados separados do ajuste e da seleção.

2.2.5 Métodos de Estimativa e Avaliação

A média aritmética constitui uma referência sem treinamento:

$$\widehat{T}_p(t) = \frac{1}{k}\sum_{i=1}^{k} T_i(t). \tag{2.3}$$

Ela atribui pesos iguais às entradas e não ajusta diferenças sistemáticas entre o nível térmico dos sensores e o do alvo.

A interpolação pelo inverso da distância (*Inverse Distance Weighting* – IDW) atribui maior peso a observações próximas:

$$\widehat{T}_p(t) = \frac{\sum_{i=1}^{k} T_i(t) d_{ip}^{-q}}{\sum_{i=1}^{k} d_{ip}^{-q}}, \tag{2.4}$$

em que $d_{ip} > 0$ é a distância ao ponto estimado e $q > 0$ controla o decaimento dos pesos. Na coincidência espacial com um sensor, atribui-se seu valor diretamente.

O Kriging é um método de interpolação geoestatística que utiliza a estrutura de dependência espacial entre observações para estimar valores em posições não medidas. Diferentemente do IDW, que determina os pesos a partir das distâncias, o Kriging considera um modelo de correlação espacial para calcular as estimativas. Embora Jedermann *et al.* (2011) tenham observado vantagens do Kriging em relação ao IDW nos conjuntos avaliados, a escolha do IDW neste trabalho não teve como objetivo identificar o método de interpolação espacial mais preciso. O IDW foi empregado exclusivamente como recurso de visualização exploratória, em razão de sua simplicidade e da possibilidade de representar a influência das observações em função da distância. Sua aplicação não substitui uma validação espacial e não permite concluir que as temperaturas interpoladas correspondam às condições reais em posições não instrumentadas.

A regressão linear estima o alvo por uma combinação ajustada das entradas:

$$\widehat{T}_p(t) = \beta_0 + \sum_{i=1}^{k} \beta_i T_i(t), \tag{2.5}$$

em que β_0 é o intercepto e β_i são os coeficientes estimados no treinamento. A Random Forest, apresentada por Breiman (2001), combina árvores de decisão; em regressão, as estimativas das árvores são agregadas. Essa estrutura permite representar relações não lineares, mas não assegura menor erro que uma alternativa linear em qualquer conjunto de dados.

A comparação utiliza o erro absoluto médio (*Mean Absolute Error* – MAE) e a raiz do erro quadrático médio (*Root Mean Squared Error* – RMSE):

$$\mathrm{MAE} = \frac{1}{n} \sum_{j=1}^{n} |T_j - \widehat{T}_j|, \tag{2.6}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n} \sum_{j=1}^{n} (T_j - \widehat{T}_j)^2}. \tag{2.7}$$

As duas métricas possuem a unidade da temperatura, mas o RMSE penaliza mais os erros elevados. T_j é o valor observado, $\widehat{T}_j$ é a estimativa e n é o número de observações. Sua interpretação exige informar a divisão temporal, os alvos e as amostras utilizados.

2.2.6 Relação com o Conforto Térmico

Temperatura e umidade são relevantes à caracterização ambiental, mas a interpretação do conforto envolve outras condições. A apresentação institucional da ASHRAE Standard 55 relaciona fatores ambientais — temperatura, radiação térmica, umidade e velocidade do ar — e pessoais, como atividade e vestimenta (ASHRAE, s.d.). Assim, uma temperatura reconstruída com baixo erro não permite, isoladamente, classificar a satisfação térmica dos ocupantes.

O presente conjunto não inclui caracterização da radiação térmica, da velocidade do ar, da atividade ou da vestimenta, nem votos de sensação térmica. Esses fatores não foram substituídos por valores arbitrários para produzir um índice. A reconstrução e a representação espacial são tratadas como recursos analíticos que poderiam apoiar uma avaliação de conforto futura, mediante protocolo e dados adequados.

2.3 Trabalhos Relacionados

Marques *et al.* (2026) apresentam uma infraestrutura IoT com ESP32, MQTT, CoAP, atualização remota de firmware e observabilidade. Os autores relatam redução de 55,7% no consumo mensal de energia em seu cenário de controle de climatização, mantendo condições de conforto. Essa evidência caracteriza a aplicação da infraestrutura estudada pelos autores; o presente trabalho utiliza históricos de temperatura e não reproduz o experimento energético.

Tavoni *et al.* (2026) apresentam uma arquitetura modular de gêmeo digital para otimização energética em um laboratório da USP. A solução integra sensores de temperatura e umidade DHT22, sensores de corrente SCT-013, comunicação MQTT, Eclipse Ditto e uma interface em Unity. O componente preditivo utiliza XGBoost para estimar consumo em kWh, com valores anteriores de energia, temperatura e umidade, validação por *TimeSeriesSplit* e parada antecipada no treinamento.

O artigo descreve cenários de simulação com diferentes configurações de operação e reconhece limitações relacionadas ao período experimental e à generalização. Sua contribuição para este TCC está na integração de dados heterogêneos e no uso de aprendizado de máquina para apoiar análises da climatização. Neste trabalho, a resposta é a temperatura de um sensor e a avaliação usa uma divisão temporal fixa; não foram implementados gêmeo digital, XGBoost, simulação de consumo ou atuação.

O trabalho de Brunello *et al.* (2021) constitui a referência mais próxima do problema investigado. Os autores analisam métricas de distância espaciais e estatísticas, desenvolvem uma combinação por programação genética e selecionam subconjuntos de sensores para estimar temperaturas em um escritório. Avaliam diferentes estratégias de predição e a confiabilidade das saídas. O presente estudo adota uma comparação mais restrita, com métodos simples e duas regras de seleção, aplicada aos dispositivos e históricos disponíveis no LASDPC.

Yuan *et al.* (2025) investigam reconstrução de campos térmicos em regimes estacionários e transientes, com cenários numéricos de condução de calor. Comparam configurações esparsas de sensores e métodos baseados em decomposição ortogonal própria (*Proper Orthogonal Decomposition* – POD), incluindo Gappy POD e Gappy C-POD. O estudo fundamenta a relevância da configuração das medições. Entretanto, a otimização de posições em cenários numéricos difere da condição deste TCC, que utiliza sensores reais previamente instalados.

Jedermann *et al.* (2011) aplicam interpolação espacial a dados de armazenamento e transporte de alimentos, comparando Kriging com ponderação pelo inverso da distância. Nos conjuntos avaliados pelos autores, o erro de Kriging foi aproximadamente 20% menor que o da referência IDW. O trabalho sustenta a discussão de relações espaciais, mas não transfere esse resultado diretamente ao ambiente do LASDPC. Neste TCC, a IDW é usada apenas para ilustrar as médias espaciais.

AlSalehy e Bailey (2025) avaliam identificação de anomalias e imputação em séries de gases e variáveis meteorológicas, combinando métodos estatísticos e algoritmos de detecção, além de interpolação linear, PCHIP e Akima. Sua relação com o presente estudo é a atenção à continuidade e à qualidade das séries. A decisão experimental aqui adotada foi selecionar janelas completas, sem reproduzir as técnicas de imputação desse artigo.

Por fim, Cho, Chang e Hwang (2022) investigam combinações de tratamento de valores ausentes e desbalanceamento para classificação industrial. Embora a aplicação seja distinta da

reconstrução de temperaturas, o artigo reforça que a preparação dos dados integra o procedimento de avaliação e deve ser descrita com precisão.

Os trabalhos apresentados abordam diferentes aspectos relacionados ao monitoramento ambiental, ao sensoriamento virtual e à reconstrução de temperaturas.

Embora apresentem objetivos e metodologias distintos, fornecem fundamentos para as escolhas realizadas neste estudo.

A Tabela 1 sintetiza o foco principal de cada trabalho e sua relação com a abordagem adotada, destacando as contribuições utilizadas na definição e na avaliação dos experimentos.

Tabela 1 – Síntese dos principais trabalhos relacionados e suas contribuições para o presente estudo.

Trabalho	**Foco principal**	**Relação com o presente trabalho**
Marques et al. (2026)	Infraestrutura IoT para monitoramento e controle de climatização.	Contextualização da infraestrutura de sensoriamento e armazenamento de dados.
Tavoni et al. (2026)	Gêmeo digital e análise energética com dados ambientais.	Fundamentação da integração de diferentes grandezas ambientais.
Brunello et al. (2021)	Sensoriamento virtual de temperatura e seleção de sensores.	Principal referência metodológica para reconstrução e seleção de entradas.
Yuan et al. (2025)	Reconstrução de campos térmicos com sensores distribuídos.	Importância da distribuição espacial dos sensores.
Jedermann et al. (2011)	Interpolação espacial de temperaturas por Kriging e IDW.	Fundamentação da representação espacial das temperaturas.
AlSalehy e Bailey (2025)	Detecção de anomalias e imputação em séries temporais	Fundamentação dos cuidados com a qualidade e continuidade dos dados
Cho, Chang e Hwang (2022)	Pré-processamento e tratamento de dados em classificação	Importância da preparação dos dados para a avaliação experimental
Presente trabalho	Reconstrução virtual de temperaturas no LASDPC.	Avaliação experimental com dados históricos de sensores IoT existentes.

Fonte: Elaborada pelo autor.

2.4 Considerações Finais

A revisão bibliográfica apresentou conceitos e trabalhos relacionados ao monitoramento ambiental, ao sensoriamento virtual e à reconstrução de temperaturas. Os estudos sobre infraestrutura IoT e gêmeos digitais contextualizam a integração de diferentes fontes de informação e suas possíveis aplicações no monitoramento e na climatização de ambientes internos.

Entre os trabalhos analisados, o estudo de Brunello *et al.* (2021) apresenta maior proximidade com a abordagem adotada, especialmente pela investigação da reconstrução virtual de temperaturas e da seleção de sensores de referência. Os demais trabalhos contribuem para

fundamentar aspectos relacionados à organização das medições, à distribuição espacial dos sensores e ao aproveitamento de diferentes grandezas ambientais.

Diferentemente de abordagens voltadas à otimização do posicionamento físico dos sensores ou ao desenvolvimento de novos algoritmos, o presente trabalho concentra-se na avaliação de métodos de reconstrução aplicados a uma infraestrutura já existente. Busca-se, assim, investigar o desempenho de diferentes estratégias de estimativa, a influência da quantidade e da seleção de sensores de entrada e a contribuição de informações complementares, considerando as características e limitações dos dados disponíveis no LASDPC.

O capítulo seguinte apresenta a infraestrutura utilizada, os procedimentos de preparação dos dados, a metodologia experimental e os resultados obtidos.

Capítulo 3

DESENVOLVIMENTO DO TRABALHO

3.1 Considerações Iniciais

Este capítulo descreve a infraestrutura e o recorte experimental, a preparação das séries e a avaliação da reconstrução de temperaturas. Apresenta também os resultados por método e sensor-alvo, a influência da quantidade de entradas e a análise espacial complementar.

3.2 Descrição do Problema e do Ambiente

3.2.1 Problema de reconstrução

O problema investigado consiste em reconstruir a temperatura registrada por um sensor físico a partir das medições dos demais dispositivos do mesmo ambiente. Para avaliar essa abordagem, cada sensor é tratado, alternadamente, como um alvo cuja temperatura deve ser estimada, simulando sua indisponibilidade durante a reconstrução. Dessa forma, suas medições são excluídas das variáveis de entrada, enquanto as temperaturas registradas pelos demais sensores são utilizadas para produzir as estimativas.

Nos métodos supervisionados, o histórico do sensor-alvo é utilizado como referência durante o treinamento dos modelos. Posteriormente, as temperaturas estimadas são comparadas com os valores reais registrados pelo dispositivo no conjunto de teste, permitindo quantificar os erros de reconstrução. As estimativas são realizadas a partir de medições correspondentes ao mesmo intervalo temporal, não constituindo, portanto, uma previsão de temperaturas futuras.

Embora o procedimento utilize sensores físicos existentes para permitir uma avaliação quantitativa, o sensoriamento virtual apresenta potencial para apoiar a estimativa de temperaturas em posições não instrumentadas do ambiente. Entretanto, essa possibilidade exigiria uma estratégia específica de reconstrução espacial e validação adicional, não sendo diretamente demonstrada pelos experimentos realizados neste trabalho. A investigação concentra-se, assim, na avaliação de métodos de reconstrução aplicados a uma infraestrutura preexistente, sem modificar o posicionamento dos sensores ou propor novos algoritmos.

3.2.2 Ambiente experimental e cadastro

O trabalho utiliza a infraestrutura do Laboratório de Sistemas Distribuídos e Programação Concorrente (LASDPC), do Instituto de Ciências Matemáticas e de Computação (ICMC), da Universidade de São Paulo (USP). O experimento principal considera os registros de temperatura associados ao ambiente `1006` no QuestDB, correspondentes a nove sensores físicos. A Figura 1 apresenta uma representação aproximada da planta do laboratório, com a identificação e a localização dos dispositivos cujas posições foram mapeadas. Informações adicionais sobre a infraestrutura e imagens do laboratório estão disponíveis na página do projeto Smart LASDPC[1].

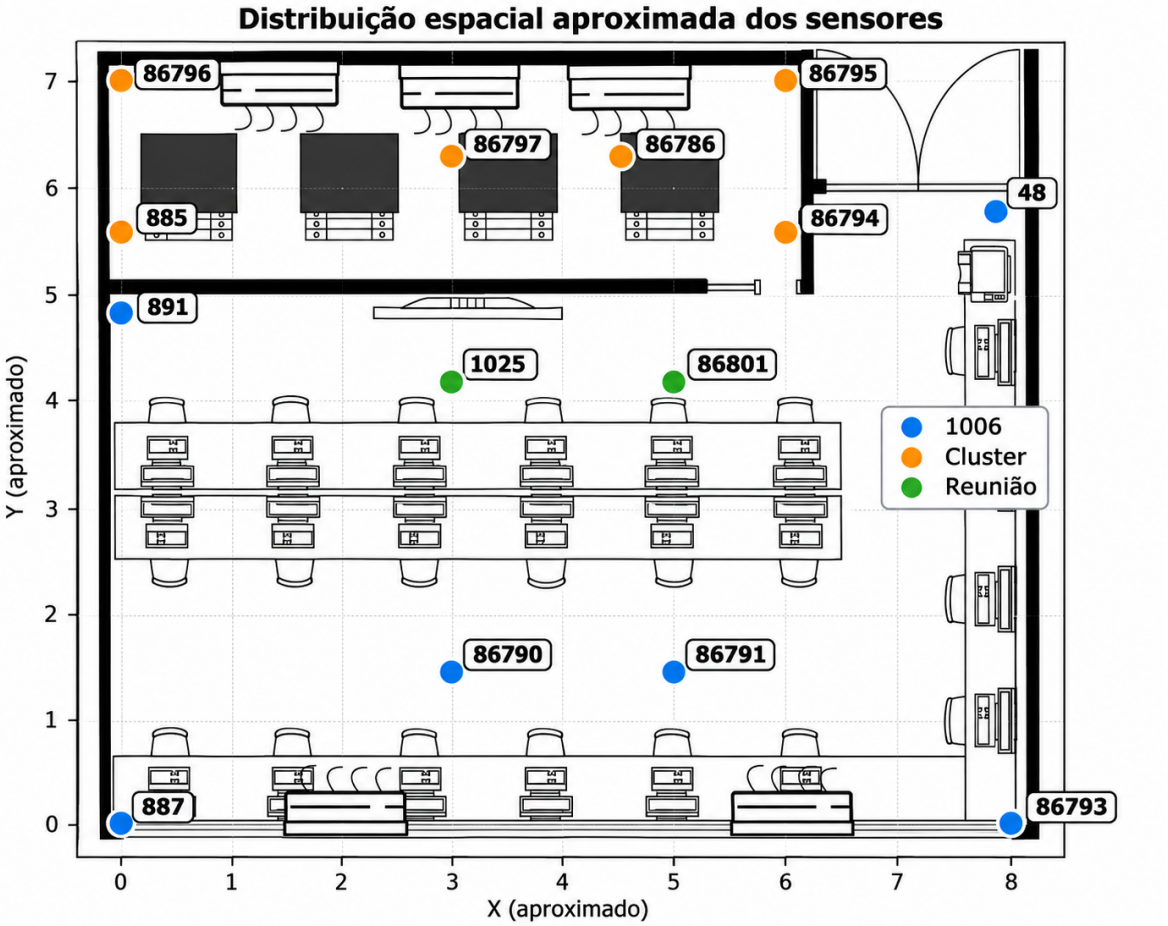


Figura 1 – Distribuição espacial aproximada dos sensores no ambiente do LASDPC. As cores representam os grupos cadastrais 1006, Cluster e Reunião, enquanto os eixos indicam coordenadas relativas.

Fonte: Elaborada pelo autor.

O cadastro da plataforma e a organização física do laboratório representam aspectos distintos. As categorias 1006, Cluster e Reunião identificam grupos de dispositivos no inventário consultado, mas não correspondem necessariamente a ambientes termicamente isolados. Conforme ilustrado na Figura 1, a região do cluster é separada da área principal por uma divisória, com uma abertura à direita. Essa configuração foi considerada na interpretação da distribuição espacial dos sensores.

[1] <https://smart-lasdpc.github.io/about-project.html>

Foram mapeadas coordenadas relativas e aproximadas para 14 dispositivos, representados na Figura 1. Entretanto, apenas seis deles pertencem ao conjunto principal de nove sensores utilizado nos experimentos com dados do QuestDB: 48, 887, 891, 86790, 86791 e 86793. Os outros três sensores do conjunto principal não possuem coordenadas confirmadas e, portanto, não foram incluídos nas análises que dependem de informações espaciais.

Dessa forma, os experimentos de comparação entre métodos de reconstrução utilizam os nove sensores do conjunto principal, enquanto a análise complementar de seleção por proximidade considera apenas os seis dispositivos com posições conhecidas. Os demais sensores representados na planta contribuem para a caracterização do ambiente, mas suas medições não integram os experimentos consolidados. O mapa apresentado na Seção 3.4.7 utiliza as coordenadas confirmadas para representar as temperaturas médias observadas nos sensores e ilustrar sua distribuição espacial por meio de interpolação.

3.2.3 Infraestrutura de monitoramento e armazenamento

A infraestrutura está relacionada à plataforma apresentada por Marques *et al.* (2026), com dispositivos baseados em ESP32, comunicação e armazenamento de séries temporais. Na exploração do QuestDB, os dispositivos do conjunto principal foram associados ao modelo DHT22. A resposta principal é a temperatura; uma análise complementar inclui umidade como entrada e uma auditoria caracteriza o campo de energia. Não foi realizado controle de climatização.

No QuestDB, as tabelas identificadas foram `sensor_temperature`, `sensor_humidity` e `sensor_energy`. A primeira contém o instante `measured_in`, o identificador `sensor_id`, o modelo, o ambiente e a temperatura. As consultas SQL foram realizadas em Python, por interface HTTP, e as extrações preservadas localmente. A API Smartlab foi explorada separadamente para consultar o cadastro e outros dispositivos. As diferenças de disponibilidade entre as extrações são discutidas na Seção 3.4.5.

3.3 Descrição das Atividades Realizadas

A metodologia foi organizada em etapas de aquisição, preparação e análise dos dados, seguidas pela execução de experimentos de reconstrução virtual de temperaturas. A Figura 2 apresenta uma visão geral desse procedimento, destacando o processamento comum das séries temporais e as diferentes configurações experimentais avaliadas. Os experimentos complementares investigam a influência da quantidade e da seleção de sensores de referência, bem como a contribuição da umidade relativa para as estimativas.

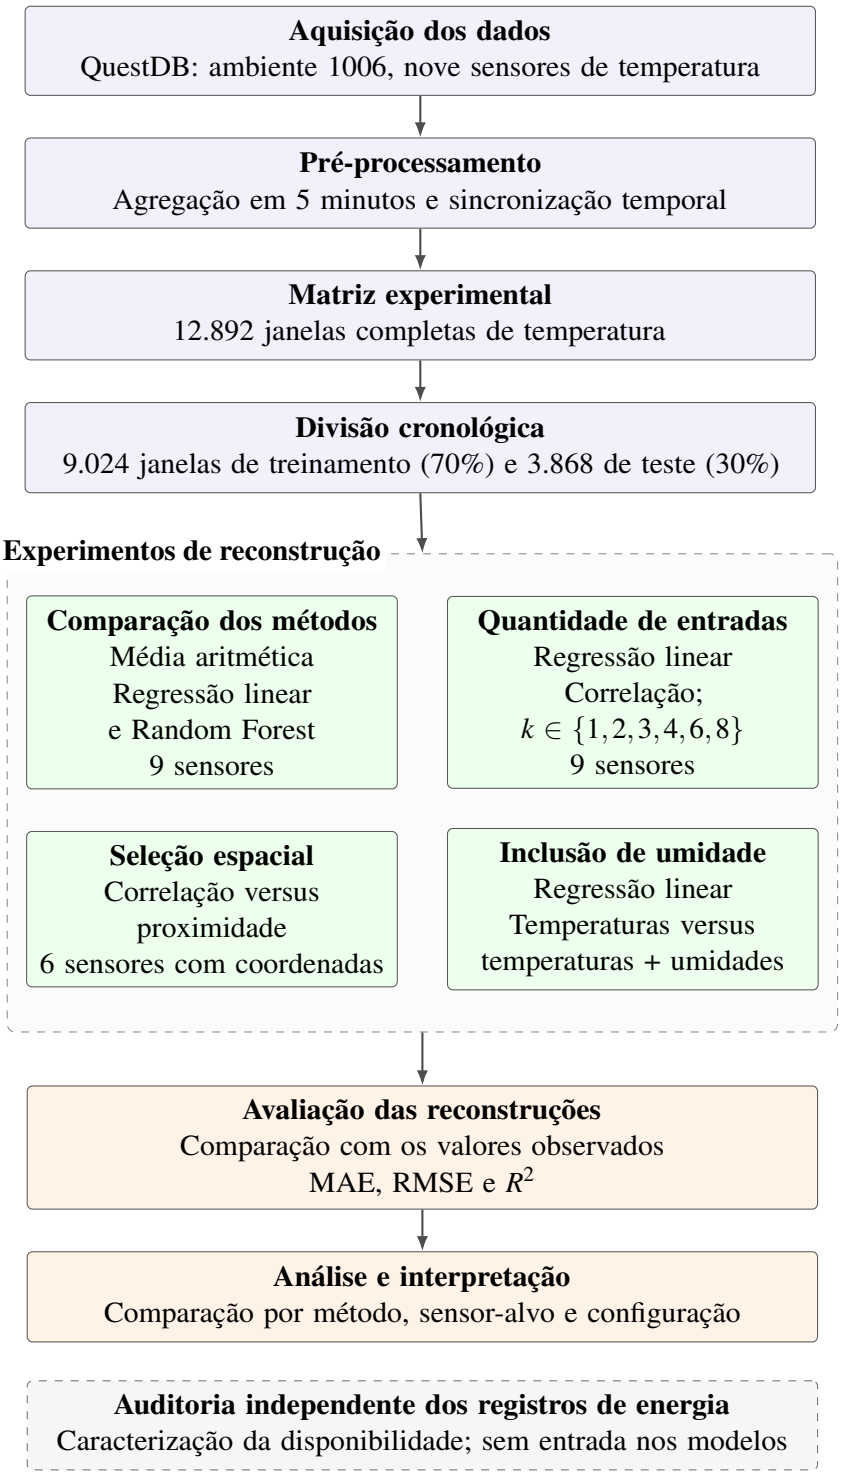


Figura 2 – Visão geral da preparação dos dados, dos experimentos de reconstrução e da avaliação. A análise espacial considera seis sensores com coordenadas conhecidas, e o experimento com umidade utiliza amostras pareadas. A auditoria de energia é independente dos modelos de reconstrução.

Fonte: Elaborada pelo autor.

3.3.1 Operacionalização do Enriquecimento

A base foi organizada em três níveis. Primeiro, as consultas e a grade temporal estruturaram as observações para análise conjunta. Em seguida, os identificadores foram associados ao cadastro e às coordenadas confirmadas, permitindo comparar critérios de seleção e representar os sensores. Por fim, a umidade foi alinhada às temperaturas e incluída nas entradas da regressão linear. Essas etapas são rastreáveis nos notebooks e nas tabelas exportadas.

O aprendizado supervisionado utiliza a temperatura do sensor-alvo como resposta histórica e as medições dos demais dispositivos como variáveis de entrada. Para avaliar a contribuição da umidade relativa, foram comparadas duas configurações de regressão linear: a primeira utiliza as temperaturas dos oito sensores de referência, enquanto a segunda incorpora também suas respectivas medições de umidade, totalizando 16 variáveis explicativas. Ambas foram avaliadas sobre os mesmos registros temporais para cada sensor-alvo, permitindo comparar seus resultados em condições equivalentes.

As coordenadas espaciais, por sua vez, foram utilizadas no ordenamento dos sensores por proximidade e na elaboração do mapa térmico, sem integrar diretamente as variáveis explicativas dos modelos de reconstrução. Dessa forma, a utilização das informações espaciais e a inclusão da umidade foram investigadas em experimentos complementares, e não como uma única configuração.

3.3.2 Delimitação do conjunto experimental

O experimento principal utilizou registros da tabela `sensor_temperature` do QuestDB associados ao ambiente `1006`. Foram selecionados os sensores 1, 48, 887, 891, 86782, 86789, 86790, 86791 e 86793. A consulta abrangeu o intervalo de 10 de junho de 2026, às 00h00, inclusive, a 26 de julho de 2026, às 00h00, exclusive, em UTC. Na exploração anterior, os nove sensores apresentaram registros em todos os 46 dias desse intervalo, enquanto o sensor 15 apresentou registros em 11 dias. A menor continuidade desse dispositivo sustenta sua ausência do conjunto experimental, sem implicar que os sensores selecionados tenham cobertura integral em todas as janelas temporais.

A coleta exploratória pela API Smartlab, que inclui sensores cadastrados nos grupos Cluster e Reunião, foi mantida separada deste experimento. As temperaturas utilizadas nos experimentos e no mapa térmico provêm exclusivamente da extração do QuestDB, sem combinar fontes com convenções temporais ainda não confirmadas.

3.3.3 Agregação, sincronização e valores ausentes

A consulta agrupou as temperaturas de cada sensor em intervalos de cinco minutos, por meio de `SAMPLE BY 5m`, retornando a média e a quantidade de medições por intervalo. Foram obtidas 116.438 linhas agregadas, cada uma correspondente a um par sensor–janela. Portanto,

cada linha representa um intervalo temporal agregado para determinado dispositivo, e não uma medição individual. A extração foi salva localmente em CSV, acompanhada da consulta SQL, da identificação da fonte e de um resumo criptográfico SHA-256.

Os timestamps foram interpretados em UTC e os sensores organizados em colunas. A matriz foi reindexada sobre a grade completa do período, com 13.248 janelas. Foram verificadas a presença dos nove sensores, a unicidade de cada par sensor–janela, a pertinência dos timestamps ao período e à grade, e a ausência de valores infinitos.

Para comparar os métodos nas mesmas observações, foram mantidas somente as janelas com temperatura disponível para todos os nove sensores. Esse procedimento resultou em 12.892 linhas completas (97,31% da grade), com exclusão de 356 janelas. Não houve imputação, remoção automática de temperaturas extremas ou imposição de um número mínimo de medições por janela além da existência de uma média válida. A contagem das medições foi preservada para auditoria. Assim, médias baseadas em quantidades diferentes de registros participam da avaliação, o que deve ser considerado na interpretação dos resultados.

3.3.4 Métodos de reconstrução

Cada um dos nove sensores foi utilizado, alternadamente, como alvo. Na comparação principal, os outros oito sensores forneceram as entradas. A temperatura do alvo foi utilizada como resposta no ajuste supervisionado e como referência na avaliação, sendo sempre excluída das variáveis explicativas.

A média aritmética foi adotada como referência sem treinamento, conforme a Equação 2.3. A regressão linear, descrita na Equação 2.5, foi ajustada por mínimos quadrados, com intercepto, utilizando a implementação da biblioteca Scikit-learn (PEDREGOSA *et al.*, 2011). Os coeficientes foram estimados apenas no treinamento, e a configuração completa foi exportada com a execução.

O terceiro método foi `RandomForestRegressor`, com 100 árvores, semente aleatória 42 e processamento paralelo. Foram utilizados erro quadrático como critério, amostragem com reposição, todas as variáveis como candidatas em cada divisão, profundidade máxima sem limite explícito, mínimo de duas amostras para divisão e uma por folha. Não foi realizada otimização de hiperparâmetros.

3.3.5 Protocolo temporal e métricas

A matriz completa foi ordenada cronologicamente e dividida sem embaralhamento: as primeiras 9.024 linhas foram destinadas ao treinamento e as 3.868 restantes ao teste. O treinamento compreendeu 10/06/2026 às 01h40 até 11/07/2026 às 15h55; o teste compreendeu 11/07/2026 às 16h00 até 25/07/2026 às 09h55, em UTC. As proporções 70%/30% foram

aplicadas à quantidade de linhas após a exclusão das janelas incompletas, não à duração contínua do período.

Todos os métodos foram avaliados nos mesmos timestamps, para os mesmos nove alvos. Trata-se de reconstrução contemporânea: as entradas são medições dos demais sensores na mesma janela do alvo. Como cada entrada é uma média de cinco minutos, a avaliação corresponde à reconstrução da janela agregada, e não à previsão antecipada de uma temperatura futura.

As métricas principais foram MAE e RMSE, definidos nas Equações 2.6 e 2.7, ambos em graus Celsius. Como medida complementar, calculou-se

$$R^2 = 1 - \frac{\sum_{j=1}^{n}(T_j - \widehat{T}_j)^2}{\sum_{j=1}^{n}(T_j - \overline{T})^2}, \tag{3.1}$$

em que $\overline{T}$ é a média das observações do alvo no teste. As métricas foram calculadas individualmente para cada alvo. Os resumos apresentam suas médias aritméticas entre os nove alvos, com pesos iguais. Em particular, a média dos RMSE não corresponde ao RMSE calculado reunindo todas as previsões. O desvio entre alvos, quando exportado, descreve a variabilidade de desempenho entre sensores-alvo, sem constituir intervalo de confiança.

3.3.6 Quantidade e seleção de sensores de entrada

Um segundo experimento utilizou regressão linear com $k \in \{1,2,3,4,6,8\}$ entradas. Para cada alvo, os demais sensores foram ordenados pela correlação de Pearson em ordem decrescente, calculada exclusivamente no treinamento. Os primeiros k sensores desse ordenamento forneceram as entradas. A divisão temporal, os nove alvos e as amostras de teste permaneceram iguais aos da comparação principal. Com oito entradas, as métricas foram conferidas contra as da regressão linear do primeiro experimento.

O procedimento permite descrever o efeito de variar k com uma regra de seleção fixa. Não compara diretamente essa regra com seleção aleatória ou proximidade espacial. O menor erro observado no teste é uma descrição das configurações avaliadas, não uma estimativa independente do desempenho de uma configuração escolhida com base nesse mesmo teste. A busca combinatória com divisão 60%/20%/20%, presente no notebook exploratório, não integra os resultados consolidados aqui.

3.3.7 Análise espacial complementar e mapa térmico

Conforme apresentado na Seção 3.2.2, foram mapeadas coordenadas relativas para 14 dispositivos, representados na Figura 1. Entretanto, apenas seis desses dispositivos pertencem ao conjunto principal de nove sensores utilizado nos experimentos com dados do QuestDB: 48, 887, 891, 86790, 86791 e 86793.

A análise espacial complementar considera exclusivamente esses seis sensores, utilizados alternadamente como alvos e candidatos a entrada. Foram preservadas as mesmas 12.892 janelas completas e a divisão temporal de 9.024 observações para treinamento e 3.868 para teste. Os sensores 1, 86782 e 86789 não participam dessa análise por não possuírem coordenadas confirmadas.

Para cada alvo, foram comparadas duas regras de seleção de entradas: correlação de Pearson decrescente no treinamento e distância euclidiana crescente nas coordenadas relativas. Foram utilizados de um a cinco sensores de entrada, com regressão linear e as mesmas métricas da comparação principal. Os empates nos ordenamentos foram resolvidos pelo menor identificador. Os valores de distância são expressos nas unidades relativas do cadastro, sem atribuição de precisão métrica. Com cinco entradas, a equivalência das métricas das duas regras foi verificada numericamente.

A planta fornecida pelo autor indica uma divisória entre o cluster e a região dos demais sensores, com uma abertura de comunicação à direita. Para representação gráfica, a divisória horizontal foi aproximada por $y = 5{,}1$, entre $x = 0$ e $x = 5{,}7$, e a parede vertical por $x = 6{,}2$, acima de $y = 5{,}1$. Essas posições foram inferidas da figura e não constituem um levantamento de paredes. Os sensores do cluster não foram candidatos nos experimentos espaciais; assim, a seleção não atravessa a divisória para escolher entradas desse espaço.

O mapa térmico apresenta a média de cada um dos seis sensores nas mesmas 12.892 janelas do período completo. Uma interpolação pelo inverso da distância (IDW), com potência dois, foi utilizada apenas para visualizar uma distribuição espacial estimada dessas médias. Em cada ponto da grade, empregaram-se os seis valores observados; na coincidência com um sensor, atribuiu-se diretamente seu valor. O preenchimento foi limitado ao envoltório convexo dos sensores, com exclusão da região do cluster. As posições dos outros dispositivos foram indicadas sem temperaturas e sem preenchimento no cluster.

A IDW não foi avaliada como método de reconstrução neste experimento. O mapa não representa uma medição contínua do campo térmico, não resolve as trocas de calor através da abertura e não descreve uma condição instantânea. As médias do período completo são usadas apenas nessa visualização, sem participar da seleção das entradas ou do ajuste dos modelos de regressão.

3.3.8 Umidade como informação complementar

Uma extensão avaliou se a umidade dos sensores de entrada acrescenta informação à reconstrução de temperatura. Os registros da tabela `sensor_humidity` foram consultados para os mesmos nove identificadores, ambiente e limites UTC do experimento principal. A grandeza foi tratada como umidade relativa (UR), em porcentagem, coerente com os dispositivos DHT22 identificados no banco e com a documentação técnica da família AM2302 (GUANGZHOU

AOSONG ELECTRONICS, s.d.). Essa identificação não substitui a verificação metrológica dos dispositivos.

A consulta retornou média, mínimo, máximo e contagens por sensor e janela de cinco minutos. A matriz foi reindexada na mesma grade de 13.248 janelas. O critério de validade exclui integralmente janelas sem valores numéricos ou com mínimo abaixo de 0% ou máximo acima de 100%; nenhuma das janelas retornadas dos nove sensores foi excluída por esse critério. Lacunas foram preservadas, sem imputação.

Foram comparadas duas regressões lineares com intercepto: uma com as oito temperaturas dos demais sensores e outra com essas mesmas temperaturas e suas oito umidades, totalizando 16 variáveis. Nem a temperatura nem a umidade do alvo integram as entradas. Para cada alvo, ambas as variantes foram ajustadas nas mesmas linhas de treinamento e avaliadas nos mesmos timestamps de teste. A seleção de casos completos considera apenas as umidades de entrada, sem exigir a disponibilidade da umidade do alvo.

Foi mantida a fronteira temporal de 11/07/2026 às 16h00 UTC, sem refazer o corte proporcional após a seleção. Todos os alvos mantiveram 9.024 linhas de treinamento. Para o alvo 48, foram preservadas as 3.868 linhas de teste; para os demais, foram retidas 3.866, pois duas janelas não possuíam todas as umidades de entrada. A referência com somente temperaturas foi reajustada nesse mesmo subconjunto, evitando atribuir ao enriquecimento uma diferença decorrente das amostras. As médias das métricas foram calculadas com pesos iguais entre alvos.

3.3.9 Auditoria exploratória do campo de energia

A tabela `sensor_energy` foi consultada para o mesmo ambiente e período do experimento principal, preservando os identificadores dos dispositivos, os modelos registrados e os limites temporais. Os dados disponíveis foram agregados em intervalos de cinco minutos para caracterização e comparação temporal com as séries de temperatura.

Entre os registros consultados, o dispositivo de identificador 23 estava associado ao modelo ACS712, destinado à medição de corrente elétrica (ALLEGRO MICROSYSTEMS, s.d.). Embora esse componente permita obter medidas de corrente em ampères (A), não foi possível confirmar a unidade física dos valores armazenados no campo `energy` a partir das informações disponíveis sobre o processamento das medições. Por esse motivo, os registros foram mantidos em sua escala original, sem conversões para corrente, potência ou consumo energético.

Dessa forma, essa etapa foi limitada à caracterização da disponibilidade dos registros e à comparação temporal exploratória com as temperaturas observadas. Não foram realizadas inferências sobre os estados de funcionamento dos equipamentos ou estabelecidas relações causais entre os registros elétricos e as condições térmicas do ambiente.

3.3.10 Organização e rastreabilidade

O notebook `02_preprocessamento.ipynb` produz as matrizes, as contagens e a auditoria da preparação; o `03_experimentos.ipynb` lê a matriz local e exporta métricas, previsões, figuras e configuração da execução. A execução consolidada foi registrada em 30 de outubro de 2026, com Python 3.12.3, NumPy 2.5.4, Pandas 3.0.6 e Scikit-learn 1.9.1. O notebook `04_analise_espacial.ipynb` executa a comparação espacial, o inventário das extrações locais e a geração do mapa. O arquivo de configuração preserva as versões, os parâmetros, os limites dos conjuntos e o SHA-256 da matriz utilizada. As extensões de umidade e energia foram executadas em 31 de outubro de 2026 nos notebooks `05_umidade.ipynb` e `06_energia_exploratoria.ipynb`, com consultas, caches e configurações próprios, preservando os experimentos anteriores.

Os códigos utilizados na preparação dos dados, na execução dos experimentos e na geração das visualizações estão disponíveis no repositório público do projeto no GitHub[2]. O repositório reúne os materiais de implementação e documentação associados ao desenvolvimento deste trabalho, permitindo consultar os procedimentos adotados e apoiar sua reprodução.

3.4 Resultados Obtidos

3.4.1 Caracterização dos dados

A Tabela 2 apresenta a disponibilidade e as estatísticas das temperaturas agregadas no período consultado. As estatísticas foram calculadas com as janelas válidas de cada sensor, antes da seleção das linhas completas. A cobertura variou de 97,39% a 97,85%. A utilização conjunta dos nove sensores reteve 12.892 das 13.248 janelas, correspondendo a 97,31% da grade temporal.

Tabela 2 – Disponibilidade e estatísticas das médias de cinco minutos.

Sensor	Janelas válidas	Ausentes	Cobertura (%)	Média (°C)	Desvio (°C)
1	12944	304	97,71	21,994	1,185
48	12902	346	97,39	22,113	0,993
887	12931	317	97,61	22,617	1,154
891	12954	294	97,78	19,847	0,805
86782	12963	285	97,85	22,002	1,187
86789	12918	330	97,51	21,551	1,172
86790	12925	323	97,56	24,019	1,155
86791	12941	307	97,68	23,275	1,168
86793	12960	288	97,83	22,494	1,277

Fonte: Elaborada pelo autor.

As médias temporais diferem entre dispositivos: o sensor 891 apresentou 19,847 °C, enquanto o sensor 86790 apresentou 24,019 °C. Essas diferenças mostram que a média indiscri-

[2] <https://github.com/GuScarenci/temperatureMonitoring>

minada dos demais sensores pode não representar o nível térmico de todos os alvos. Entretanto, as estatísticas não permitem atribuir tais diferenças a causas específicas, como posição, climatização ou calibração.

3.4.2 Comparação entre métodos

A Tabela 3 resume o desempenho no teste. Os métodos supervisionados apresentaram menores erros médios entre alvos que a média aritmética. A Random Forest obteve MAE médio de 0,254 °C, e a regressão linear, 0,257 °C. A diferença de MAE foi aproximadamente 0,0024 °C. Por outro lado, a regressão linear apresentou menor média dos RMSE: 0,325 °C, contra 0,332 °C da Random Forest. Não houve, portanto, predominância do mesmo método nas duas métricas, e não foi realizado teste de significância estatística dessa diferença.

Tabela 3 – Médias das métricas entre os nove sensores-alvo no teste.

Método	MAE (°C)	RMSE (°C)	R^2
Média aritmética	0,927	0,991	-2,362
Random Forest	0,254	0,332	0,852
Regressão linear	0,257	0,325	0,850

Fonte: Elaborada pelo autor.

O R^2 médio negativo da média aritmética não implica desempenho negativo em todos os alvos. Sua agregação é fortemente influenciada pelo sensor 891, para o qual esse método obteve $R^2 = -23,519$, e pelo sensor 86790, com $R^2 = -2,497$. Um R^2 negativo indica erro quadrático superior ao da referência constante igual à média do próprio alvo no teste; essa referência serve à definição da métrica e não foi utilizada como entrada dos modelos.

3.4.3 Diferenças entre sensores-alvo

A Tabela 4 e a Figura 3 mostram que a comparação global não se aplica uniformemente aos dispositivos. A regressão linear apresentou o menor MAE em quatro alvos (48, 86789, 86790 e 86793), a Random Forest em três (887, 891 e 86791) e a média aritmética em dois (1 e 86782).

O sensor 86789 apresentou o menor MAE supervisionado: 0,090 °C com regressão linear, acompanhado de $R^2 = 0,985$. Já o sensor 891 apresentou MAE de 0,387 °C com regressão linear e 0,374 °C com Random Forest, cujos R^2 foram, respectivamente, 0,442 e 0,448. Assim, erros absolutos inferiores a meio grau nesse alvo coexistiram com uma parcela relevante de variação não explicada pelos modelos.

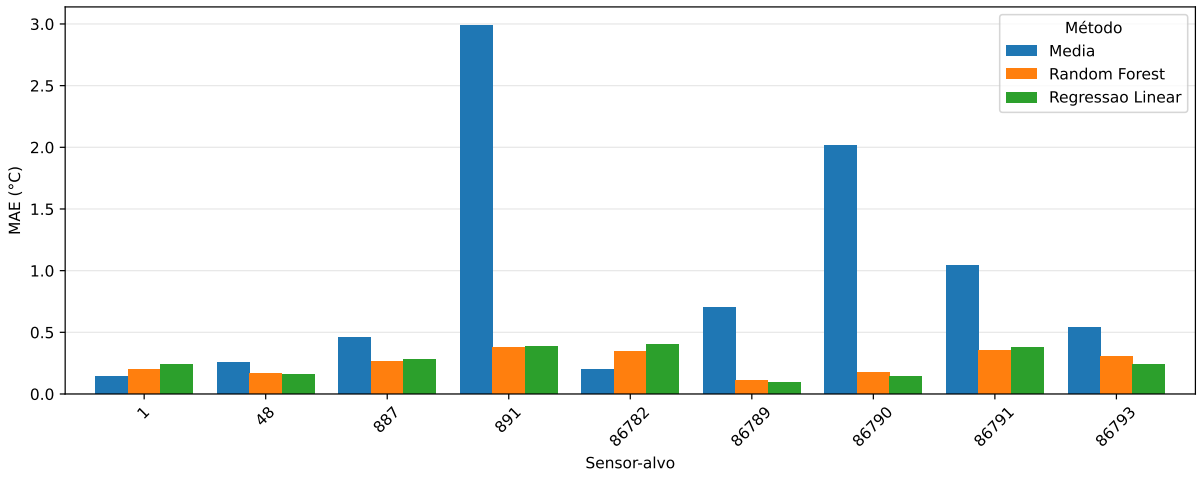
Nos sensores 1 e 86782, a média aritmética obteve MAE de 0,145 °C e 0,198 °C, respectivamente, abaixo dos dois modelos supervisionados. Esse resultado evidencia a importância de manter uma referência simples e avaliar cada alvo. O ajuste no treinamento não garante menor erro no período posterior para todos os dispositivos.

Tabela 4 – MAE por sensor-alvo e método, em graus Celsius.

Sensor-alvo	Média aritmética	Regressão linear	Random Forest
1	0,145	0,240	0,202
48	0,253	0,155	0,167
887	0,462	0,276	0,264
891	2,989	0,387	0,374
86782	0,198	0,399	0,342
86789	0,705	0,090	0,110
86790	2,014	0,145	0,176
86791	1,041	0,379	0,352
86793	0,540	0,240	0,303

Fonte: Elaborada pelo autor.

Figura 3 – Comparação do MAE por sensor-alvo no conjunto de teste.



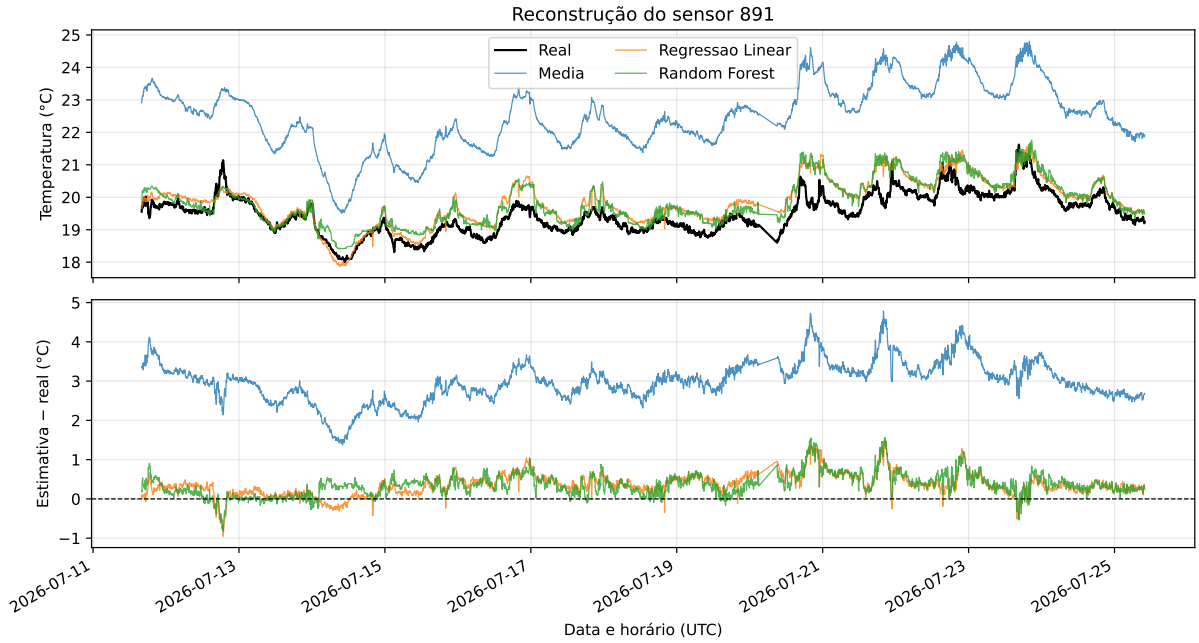
Fonte: Elaborada pelo autor.

A Figura 4 apresenta o comportamento das estimativas para o sensor 891, selecionado por apresentar o maior MAE entre os alvos avaliados pela Random Forest. O gráfico superior compara a temperatura efetivamente registrada pelo sensor com as temperaturas estimadas pelos três métodos ao longo do período de teste. Já o gráfico inferior apresenta os resíduos das estimativas, calculados pela diferença entre a temperatura estimada e a observada, permitindo visualizar a magnitude e o sentido dos erros. Valores positivos indicam superestimação, enquanto valores negativos indicam subestimação.

Observa-se que a média aritmética permanece sistematicamente acima da temperatura real, apresentando resíduos positivos elevados durante praticamente todo o período analisado. Em contrapartida, a regressão linear e a Random Forest acompanham mais de perto as variações da temperatura observada, com resíduos geralmente próximos de zero, embora ainda apresentem desvios em determinados intervalos. Esse comportamento é consistente com os menores erros absolutos médios obtidos pelos métodos supervisionados para esse sensor. A figura evidencia,

portanto, diferenças na capacidade dos métodos de reproduzir o nível térmico observado, sem permitir identificar as causas físicas dessas discrepâncias.

Figura 4 – Reconstrução da temperatura do sensor 891 no conjunto de teste: temperaturas observadas e estimadas (superior) e resíduos das estimativas (inferior).



Fonte: Elaborada pelo autor.

3.4.4 Influência da quantidade de entradas

A Tabela 5 apresenta os resultados da regressão linear com seleção por correlação no treinamento. O MAE médio diminuiu de 0,296 °C com uma entrada para 0,238 °C com quatro. Com seis e oito entradas, os valores aumentaram para 0,257 °C, aproximadamente. A média dos RMSE também atingiu seu menor valor entre as configurações avaliadas com quatro entradas, igual a 0,302 °C.

Tabela 5 – Médias das métricas da regressão linear por quantidade de entradas.

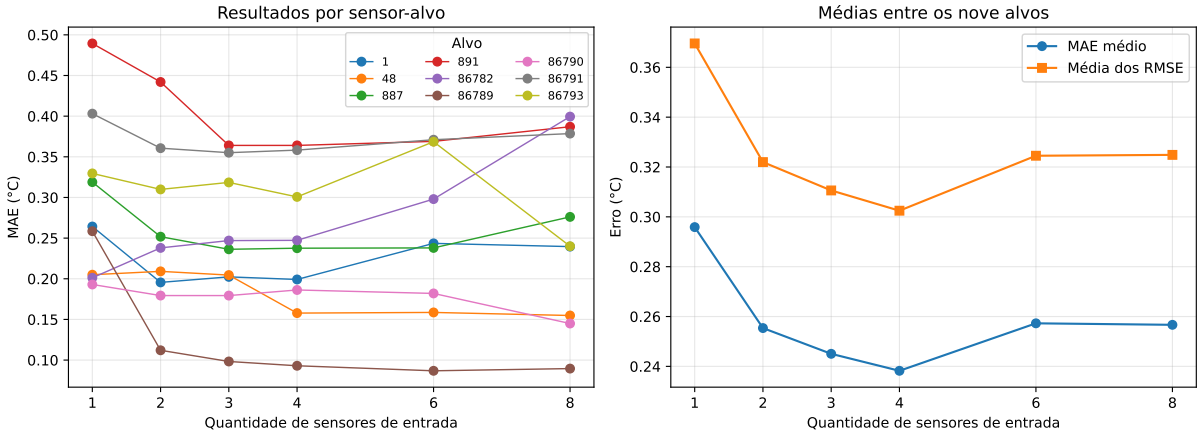
k	MAE (°C)	RMSE (°C)	R^2
1	0,296	0,370	0,816
2	0,255	0,322	0,855
3	0,245	0,311	0,875
4	0,238	0,302	0,880
6	0,257	0,325	0,864
8	0,257	0,325	0,850

Fonte: Elaborada pelo autor.

A Figura 5 evidencia que o comportamento varia conforme o alvo. Para o sensor 86782, por exemplo, o erro cresce ao aumentar o número de entradas no ordenamento adotado, enquanto

outros sensores se beneficiam da inclusão de variáveis. Portanto, o menor erro médio com quatro entradas não implica que esse número seja preferível para todos os alvos.

Figura 5 – Erros por alvo e médias em função da quantidade de entradas.



Fonte: Elaborada pelo autor.

Esses resultados indicam que, neste período e com essa regra de seleção, utilizar todos os sensores disponíveis não produziu o menor erro médio. Entretanto, não demonstram que a seleção por correlação supera outros critérios, pois não houve comparação com subconjuntos aleatórios ou selecionados por distância nesse conjunto de nove sensores. A comparação espacial complementar utiliza um recorte comum de seis sensores e é apresentada na Seção 3.4.6. Também não estabelecem uma quantidade ótima geral: quatro foi o menor erro observado entre os valores de k examinados nesse teste, sem uma avaliação independente posterior à escolha.

3.4.5 Disponibilidade dos dados nas fontes consultadas

As extrações locais evidenciam diferenças no conjunto de dispositivos consultados em cada fonte. O experimento principal contém nove sensores do ambiente 1006 no QuestDB. A coleta pela API Smartlab contém 14 sensores com coordenadas: seis do ambiente 1006, seis do cluster e dois cadastrados na reunião. Seis identificadores estão presentes em ambas as extrações. Os sensores 1, 86782 e 86789 fazem parte da extração principal do QuestDB, mas não da coleta local de 14 sensores da Smartlab. Essa ausência decorre do inventário consultado e não demonstra indisponibilidade desses dispositivos em toda a API.

Na consulta exploratória ao QuestDB preservada no notebook original, a busca pelos seis identificadores do cluster retornou um conjunto vazio, enquanto a API permitiu obter registros desses mesmos dispositivos. Esse achado documenta o resultado das consultas realizadas, sem estabelecer que as duas fontes tenham cobertura histórica equivalente ou que o estado dos servidores permaneça o mesmo.

As respostas locais da API contêm timestamps sem indicação de fuso e intervalos observados inferiores aos cinco minutos solicitados na configuração exploratória. Assim, a

contagem dessas linhas não pode ser comparada diretamente à quantidade de janelas válidas do QuestDB. A equiparação exige verificar a semântica temporal e a agregação antes de combinar os dados. Por esse motivo, o mapa e a avaliação espacial utilizam somente temperaturas do QuestDB, embora mostrem as posições cadastradas dos demais dispositivos.

3.4.6 Coordenadas e comparação da seleção espacial

A Tabela 6 relaciona as posições confirmadas dos seis sensores usados na análise complementar. As médias dessa tabela utilizam somente as janelas completas comuns aos nove sensores do experimento principal, diferentemente das estatísticas por sensor da Tabela 2.

Tabela 6 – Coordenadas relativas e médias nas 12.892 janelas comuns.

Sensor	X relativo	Y relativo	Média (°C)
48	8,0	5,6	22,114
887	0,0	0,0	22,618
891	0,0	4,9	19,850
86790	3,0	1,4	24,019
86791	5,0	1,4	23,276
86793	8,0	0,0	22,497

Fonte: Elaborada pelo autor.

A Tabela 7 e a Figura 6 apresentam a comparação entre seleção por correlação e por proximidade. Para uma a quatro entradas, a correlação apresentou menor MAE médio entre os seis alvos. Com uma entrada, os MAE médios foram 0,315 °C para correlação e 0,390 °C para proximidade; com quatro, foram 0,276 °C e 0,295 °C, respectivamente. A média dos RMSE também foi menor para a seleção por correlação nesses quatro valores de k.

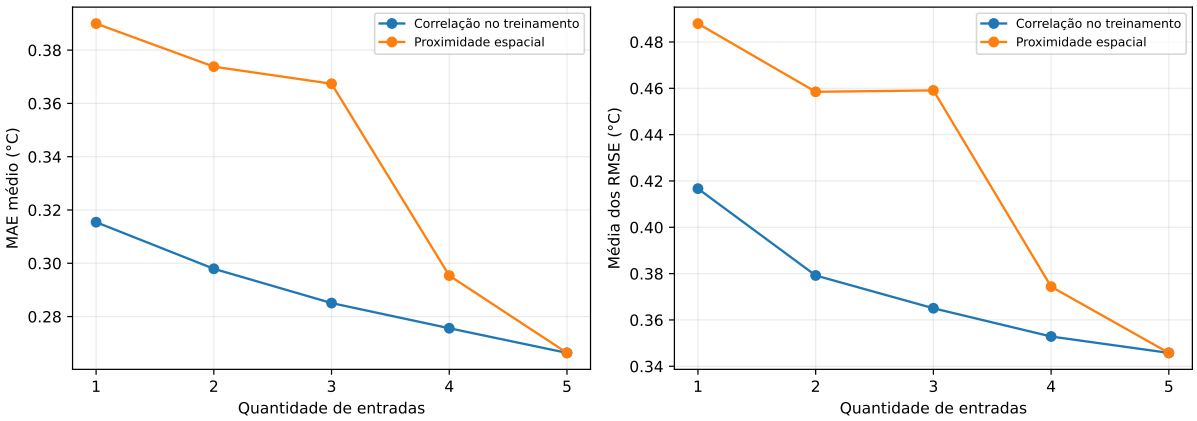
Tabela 7 – Seleção por correlação e proximidade: médias entre seis alvos (°C).

k	MAE corr.	RMSE corr.	MAE prox.	RMSE prox.
1	0,315	0,417	0,390	0,488
2	0,298	0,379	0,374	0,458
3	0,285	0,365	0,367	0,459
4	0,276	0,353	0,295	0,374
5	0,266	0,346	0,266	0,346

Fonte: Autor desta monografia. Corr.: correlação; prox.: proximidade.

Com cinco entradas, as duas regras utilizaram o mesmo conjunto de sensores e produziram MAE médio de 0,266 °C e média dos RMSE de 0,346 °C. A concordância confirma a consistência dessa comparação. Os resultados sugerem que a distância, isoladamente, não capturou as relações úteis à regressão tão bem quanto a correlação histórica nessa configuração. Não foi realizado teste de significância ou validação em períodos adicionais para generalizar essa diferença.

Figura 6 – Desempenho da regressão linear com duas regras de seleção.



Fonte: Elaborada pelo autor.

A seleção espacial é uma análise com seis candidatos e seis alvos. Seus erros médios não devem ser comparados diretamente aos da Tabela 5, que considera nove sensores. Em particular, o menor erro com cinco entradas neste recorte não contradiz o resultado com quatro entradas no conjunto anterior. A divisória também não foi avaliada como variável explicativa ou como efeito causal: ela é uma condição física documentada, e os sensores do cluster foram excluídos dos candidatos de ambas as regras.

3.4.7 Distribuição espacial das temperaturas médias

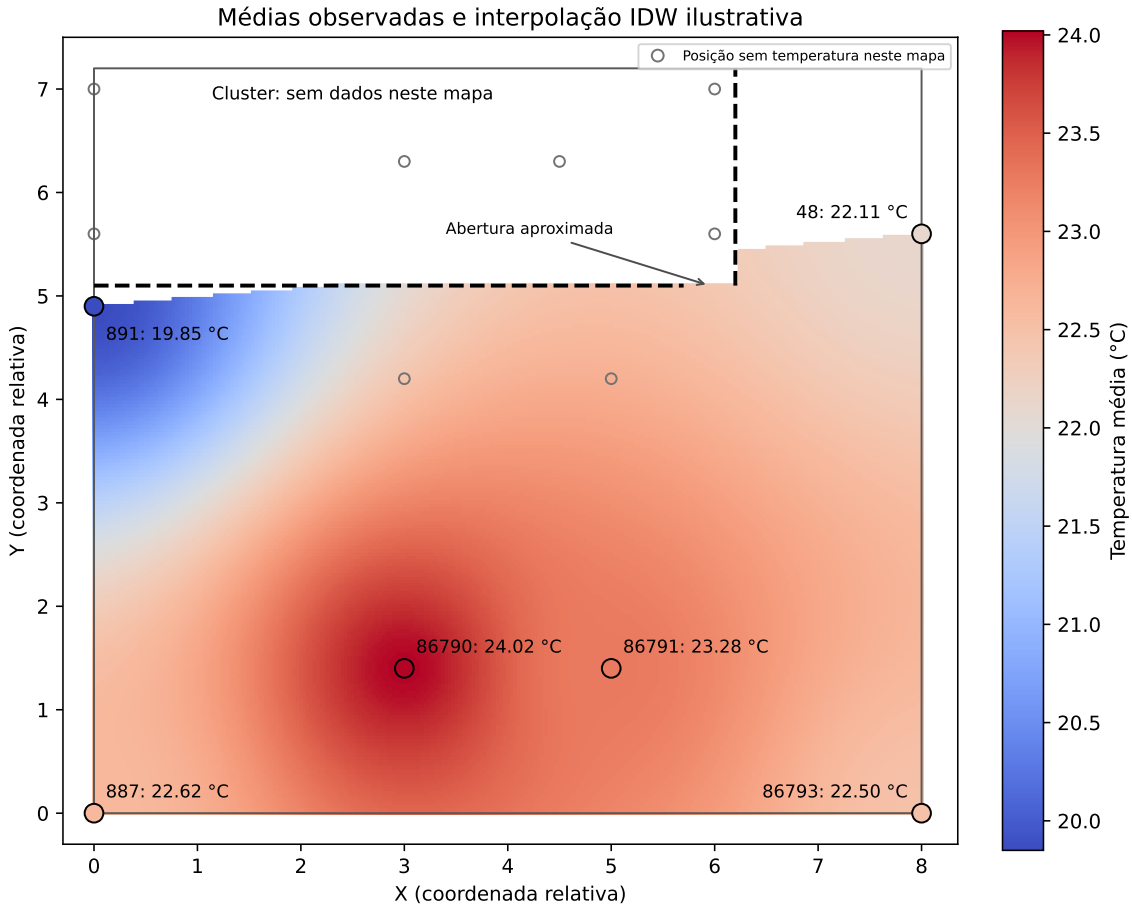
A Figura 7 apresenta os valores médios medidos nos seis pontos e a interpolação ilustrativa entre eles. O sensor 891, localizado abaixo da divisória, apresentou média de 19,850 °C, enquanto o sensor 86790 apresentou 24,019 °C. A figura permite situar espacialmente essa diferença, sem atribuí-la à divisória, aos equipamentos ou à climatização.

A área do cluster permanece sem preenchimento, evitando apresentar uma continuidade interpolada através da divisória. As paredes tracejadas e a abertura aproximada indicam a limitação geométrica da representação. A IDW suaviza as médias entre os pontos observados, mas não fornece evidência de que as temperaturas nas posições sem sensores correspondam aos valores coloridos. O mapa complementa a caracterização dos dados; a validação quantitativa continua restrita aos sensores físicos usados como alvos.

3.4.8 Caracterização da umidade e efeito do enriquecimento

A Tabela 8 apresenta a disponibilidade da umidade e as estatísticas das médias de cinco minutos, antes de restringir as amostras à comparação pareada. A cobertura variou de 97,52% a 97,85% da grade. As umidades médias variaram de 53,98% no sensor 86790 a 59,80% no sensor 891. O desvio é expresso em pontos percentuais (p.p.), para distinguir a variação da UR de uma variação percentual relativa à média.

Figura 7 – Temperaturas médias observadas e interpolação IDW ilustrativa.



Fonte: Autor desta monografia. Geometria aproximada a partir da planta; pontos coloridos: médias observadas; fundo: interpolação das médias. Regiões sem preenchimento não foram estimadas.

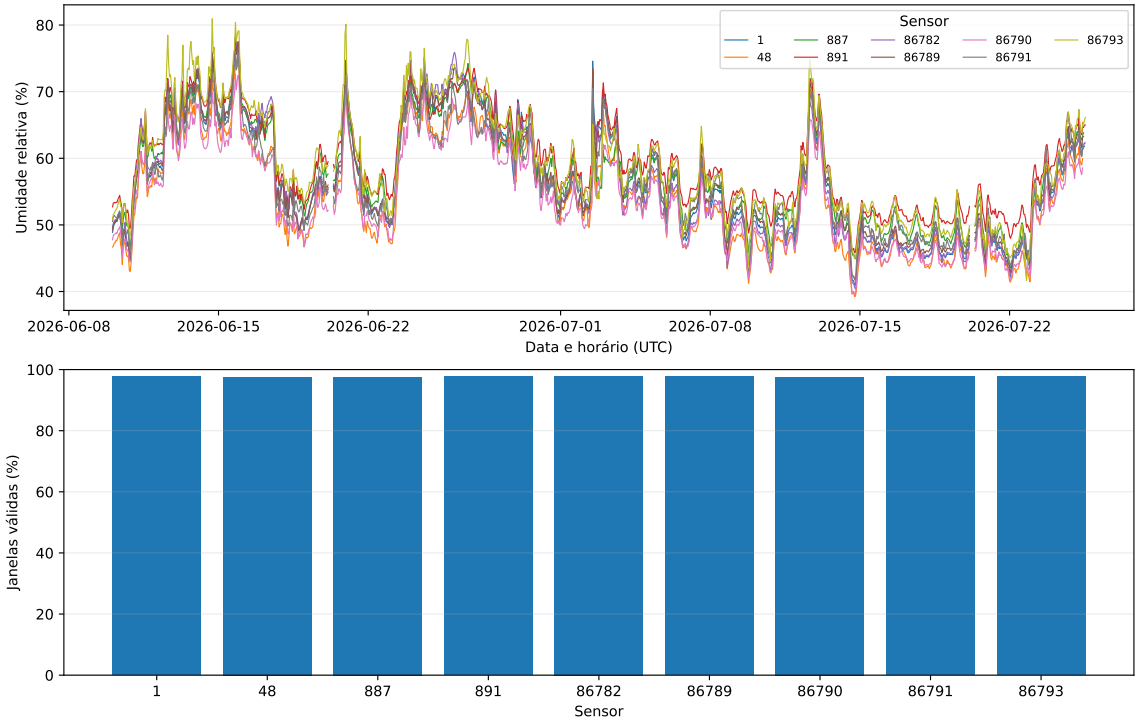
Tabela 8 – Disponibilidade e estatísticas da umidade relativa agregada.

Sensor	Janelas	Cobertura (%)	Média (%)	Desvio (p.p.)
1	12944	97,71	56,65	8,47
48	12919	97,52	54,52	8,06
887	12931	97,61	57,66	7,48
891	12954	97,78	59,80	7,09
86782	12963	97,85	56,57	8,67
86789	12938	97,66	57,14	8,25
86790	12925	97,56	53,98	7,25
86791	12941	97,68	56,75	7,25
86793	12960	97,83	59,16	8,19

Fonte: Elaborada pelo autor.

A Figura 8 mostra a evolução das médias horárias, utilizadas apenas para legibilidade, e a proporção de janelas válidas de cinco minutos. As correlações de Pearson entre temperatura e umidade do mesmo dispositivo, calculadas no treinamento, foram negativas nos nove sensores, entre $-0{,}446$ e $-0{,}108$. Esse diagnóstico não demonstra que a umidade forneça informação preditiva adicional; essa possibilidade foi examinada na comparação com entradas enriquecidas.

Figura 8 – Séries de umidade e disponibilidade das janelas no período.



Fonte: Elaborada pelo autor.

Na Tabela 9, o acréscimo de umidade reduziu o MAE médio da regressão linear de 0,25668 °C para 0,25343 °C, uma diferença de aproximadamente 0,00325 °C. A média dos RMSE passou de 0,32488 °C para 0,32250 °C. O ganho agregado foi pequeno e não foi submetido a teste de significância ou confirmado em períodos independentes.

Tabela 9 – Regressão linear com e sem umidade, nas mesmas amostras por alvo.

Entradas	MAE (°C)	RMSE (°C)	R^2
Temperaturas	0,25668	0,32488	0,850
Temperaturas e umidades	0,25343	0,32250	0,857

Fonte: Elaborada pelo autor.

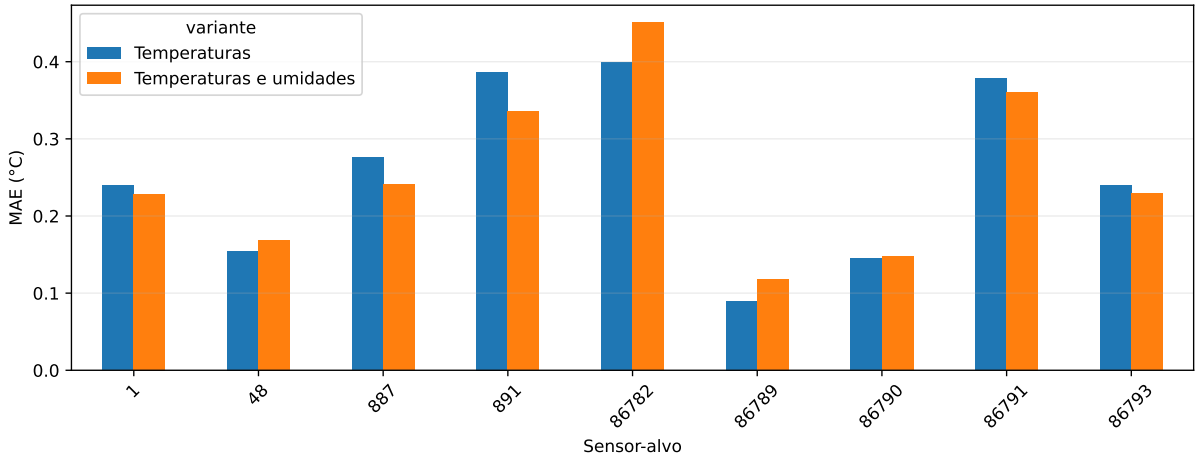
A Tabela 10 e a Figura 9 mostram que o enriquecimento reduziu o MAE em cinco alvos e aumentou em quatro. O sensor 891 apresentou redução de 0,38690 °C para 0,33541 °C; já o sensor 86782 passou de 0,39943 °C para 0,45071 °C. Assim, acrescentar uma grandeza ambiental não assegurou melhora uniforme. A avaliação não permite atribuir o resultado a uma causa específica, como posição, climatização ou mecanismo físico entre temperatura e umidade.

Tabela 10 – Efeito da umidade no MAE por alvo; diferença negativa indica redução.

Sensor	Somente T (°C)	T e UR (°C)	Δ MAE (°C)
1	0,240	0,228	-0,011
48	0,155	0,169	0,014
887	0,276	0,241	-0,035
891	0,387	0,335	-0,051
86782	0,399	0,451	0,051
86789	0,090	0,119	0,029
86790	0,145	0,148	0,003
86791	0,379	0,361	-0,018
86793	0,240	0,229	-0,011

Fonte: Elaborada pelo autor.

Figura 9 – MAE da regressão linear com e sem umidade dos sensores de entrada.



Fonte: Elaborada pelo autor.

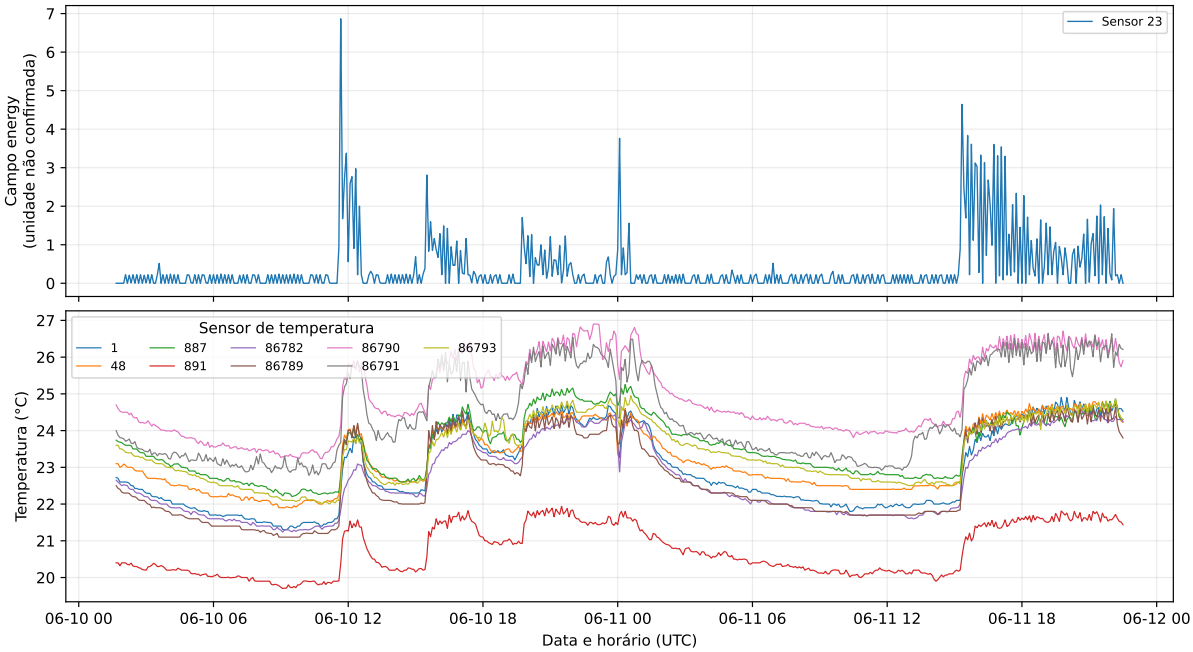
As duas variantes compartilham amostras em cada alvo, mas há duas linhas de teste a menos para oito alvos em relação ao experimento principal. Por isso, a referência dessa comparação é a regressão reajustada com somente temperaturas, e não uma comparação direta com a Random Forest ou com as médias da Tabela 3. A análise mantém temperatura como resposta; a reconstrução da própria umidade não foi avaliada.

3.4.9 Disponibilidade e interpretação dos registros de energia

A consulta à tabela de energia retornou registros apenas do sensor 23 no período selecionado: 8.193 linhas, entre 10/06/2026 às 01h43min35s e 11/06/2026 às 22h31min36s, em UTC. O sensor 2, identificado na exploração histórica, não retornou dados nesse recorte. A agregação produziu 539 janelas válidas, correspondentes a 4,07% das 13.248 previstas. Portanto, essa fonte não oferece cobertura comparável à de temperatura e umidade ao longo das seis semanas analisadas.

Os valores brutos do campo variaram de 0 a 9,13. As médias de cinco minutos variaram de 0 a 6,865, na escala registrada no banco. Como a unidade e a transformação do firmware não foram confirmadas, esses valores não são interpretados como kWh, W ou A. A Figura 10 apresenta apenas a sobreposição dos registros disponíveis e das temperaturas no mesmo trecho.

Figura 10 – Campo de energia e temperaturas no curto intervalo disponível.



Fonte: Elaborada pelo autor.

A série apresenta variações na escala registrada, mas sua sobreposição às temperaturas não identifica, por si só, estados do ar-condicionado ou efeitos causais. A curta disponibilidade e a unidade pendente de confirmação limitaram o uso desses dados à auditoria e à visualização, sem incluí-los como entradas dos modelos ou calcular consumo energético.

3.4.10 Síntese e alcance dos resultados

Os experimentos demonstraram a viabilidade da reconstrução das temperaturas médias dos sensores físicos no ambiente estudado, com erros absolutos médios próximos de 0,25 °C para os métodos supervisionados. A regressão linear e a Random Forest apresentaram desempenhos agregados semelhantes: a Random Forest obteve o menor MAE médio entre os nove alvos (0,254 °C), enquanto a regressão linear apresentou o menor RMSE médio (0,325 °C). Considerando a proximidade desses resultados e a menor complexidade estrutural da regressão linear, esta se apresenta como uma alternativa inicial adequada para a reconstrução de temperaturas no cenário avaliado. Entretanto, as diferenças de desempenho entre os sensores-alvo indicam que a escolha do método deve considerar as características de cada dispositivo, não sendo possível estabelecer uma abordagem universalmente superior.

A análise da quantidade de entradas mostrou que a utilização de todos os sensores disponíveis não necessariamente resulta em menores erros de reconstrução. Na regressão linear com seleção por correlação, quatro sensores de referência apresentaram o menor MAE médio entre as configurações avaliadas (0,238 °C), inferior ao obtido com oito entradas (aproximadamente 0,257 °C). Esse resultado sugere que subconjuntos de sensores podem fornecer informações suficientes para produzir estimativas competitivas, sem que a inclusão de todas as medições disponíveis represente necessariamente uma vantagem. Contudo, a quantidade de quatro entradas não deve ser interpretada como uma configuração ótima geral, pois seu desempenho foi identificado no próprio conjunto de teste e variou conforme o sensor-alvo.

Na análise espacial complementar, a seleção de sensores por correlação histórica apresentou menores erros médios que a seleção por proximidade física para uma a quatro entradas. Esse comportamento sugere que a distância euclidiana, isoladamente, não representa todas as relações relevantes entre as temperaturas registradas no ambiente. A observação é compatível com a importância de considerar relações estatísticas entre sensores, discutida por Brunello *et al.* (2021). Entretanto, a comparação foi realizada com apenas seis dispositivos com coordenadas confirmadas, não permitindo generalizar a superioridade de um critério de seleção para outras configurações espaciais.

O enriquecimento das entradas com medições de umidade relativa produziu uma redução pequena no MAE médio da regressão linear, de 0,25668 °C para 0,25343 °C, com melhorias em cinco sensores-alvo e aumento do erro nos outros quatro. Assim, embora a integração de diferentes grandezas ambientais seja uma possibilidade relevante para o sensoriamento virtual, os resultados não demonstraram uma vantagem uniforme ou expressiva da inclusão de umidade na configuração avaliada. Os registros de energia, por sua vez, apresentaram disponibilidade insuficiente para uma análise correspondente ao período completo, permanecendo restritos à caracterização exploratória.

Em conjunto, os resultados indicam que a reconstrução virtual pode aproveitar relações existentes entre sensores físicos para estimar temperaturas em posições previamente monitoradas, com desempenho dependente do método, do sensor-alvo e da seleção das entradas. Para o ambiente estudado, a regressão linear representa uma alternativa competitiva e relativamente simples, enquanto a seleção de subconjuntos de sensores mostrou potencial para reduzir a quantidade de informações necessárias à reconstrução.

Essas conclusões, entretanto, restringem-se às condições experimentais consideradas: um único ambiente, um período de observação e uma divisão cronológica de treinamento e teste. Não foram avaliadas situações de indisponibilidade simultânea dos sensores de referência, nem a estabilidade dos resultados em outros períodos ou configurações físicas. Além disso, a comparação utiliza as medições dos próprios sensores como referência, sem validação por instrumentos calibrados. Dessa forma, os resultados não demonstram diretamente a capacidade de estimar temperaturas em posições não instrumentadas, reconstruir um campo térmico contínuo

ou avaliar condições de conforto térmico, permanecendo essas possibilidades como perspectivas para trabalhos futuros.

3.5 Dificuldades e Limitações

A sincronização exigiu agregar medições cujos instantes de aquisição não coincidem. A exclusão de 356 janelas incompletas permitiu comparar os métodos nas mesmas amostras, mas restringe a avaliação a instantes com todas as entradas disponíveis. Portanto, os resultados não medem o desempenho durante falhas simultâneas dos sensores de entrada. As médias de cinco minutos também foram calculadas com quantidades variáveis de medições, sem impor um limite mínimo uniforme.

A avaliação utiliza um único ambiente, um período e uma divisão cronológica. A dependência temporal entre observações e a ausência de repetições em outros períodos limitam as conclusões de generalização. O teste foi examinado em diferentes configurações exploratórias; por isso, o menor erro observado não deve ser interpretado como avaliação independente de uma configuração escolhida após essa inspeção. Não foram estimados intervalos de confiança nem significância estatística das diferenças entre métodos.

As coordenadas estão disponíveis para seis dos nove sensores, e as paredes foram aproximadas a partir da planta. A distância euclidiana não modela obstáculos, circulação de ar ou trocas de calor pela abertura. O mapa interpola médias observadas e não valida um campo térmico contínuo. A separação dos registros do QuestDB e da API evita combinar convenções temporais ainda não equiparadas, mas deixa as medições do cluster fora da avaliação consolidada.

A extensão com umidade foi avaliada no mesmo período já examinado nos experimentos anteriores, sem constituir teste independente de novas hipóteses em dados inéditos. Para energia, a curta disponibilidade e a unidade não confirmada impedem interpretar os valores como consumo.

Por fim, a referência experimental é o registro de cada sensor, sem comparação com instrumento calibrado. Assim, erro reduzido de reconstrução não demonstra exatidão metrológica nem atendimento a critérios de conforto térmico. A contribuição está na avaliação dos métodos nas condições documentadas, com dados, parâmetros e previsões rastreáveis.

3.6 Considerações Finais

A avaliação mostrou erros agregados próximos entre regressão linear e Random Forest, com vantagens distintas conforme o alvo e a métrica. A quantidade de entradas e a regra de seleção influenciaram os erros; a análise espacial permitiu situar as diferenças de temperatura e comparar proximidade com correlação em condições comuns. O capítulo seguinte sintetiza essas evidências e suas possibilidades de continuidade.

Capítulo 4

CONCLUSÃO

Este trabalho investigou a reconstrução virtual de temperaturas a partir de medições de sensores IoT instalados no ambiente 1006 do LASDPC. O objetivo proposto foi atendido por meio da preparação, sincronização e enriquecimento de dados históricos de nove sensores físicos, cujas medições foram agregadas em intervalos de cinco minutos. A avaliação permitiu comparar métodos de reconstrução e investigar a influência da quantidade e da seleção de sensores de referência, bem como a contribuição de informações ambientais complementares. A principal contribuição consiste na avaliação experimental dessas estratégias em uma infraestrutura real preexistente, com procedimentos e resultados documentados para reprodução.

Na comparação principal, os métodos supervisionados apresentaram erros médios inferiores aos da média aritmética. A regressão linear obteve MAE médio entre sensores-alvo de 0,257 °C, enquanto a Random Forest alcançou 0,254 °C, em comparação a 0,927 °C da referência. A Random Forest apresentou o menor MAE médio, enquanto a regressão linear obteve a menor média dos RMSE. Entretanto, as diferenças agregadas entre os modelos supervisionados foram pequenas e o desempenho variou conforme o sensor-alvo. A média aritmética, por exemplo, apresentou menor MAE nos sensores 1 e 86782, evidenciando que nenhuma das abordagens foi superior em todos os casos.

Diante desses resultados, a regressão linear se apresenta como uma alternativa inicial competitiva para a reconstrução de temperaturas no cenário estudado, considerando sua simplicidade estrutural e seu desempenho próximo ao da Random Forest. Essa interpretação não estabelece superioridade estatística nem exclui a utilização de outros métodos, especialmente em sensores para os quais foram observadas vantagens individuais.

A investigação da quantidade de entradas mostrou que utilizar todos os sensores disponíveis não necessariamente produz estimativas mais precisas. Na regressão linear com seleção por correlação calculada exclusivamente no treinamento, quatro sensores de referência apresentaram o menor MAE médio entre as configurações avaliadas, de 0,238 °C. Esse resultado sugere que subconjuntos de sensores podem oferecer informações suficientes para reconstruções competitivas. Entretanto, o desempenho depende do sensor-alvo e da regra de seleção empregada, não sendo possível estabelecer uma quantidade universalmente ótima com base nos experimentos realizados.

Na análise espacial complementar, realizada com seis sensores de posições conhecidas, a

seleção por correlação histórica apresentou menor MAE médio que a seleção por proximidade física para uma a quatro entradas. Esse comportamento indica que a distância euclidiana, isoladamente, não foi o critério mais favorável nas configurações avaliadas. A representação espacial das temperaturas médias também permitiu visualizar diferenças entre os dispositivos, utilizando interpolação IDW exclusivamente para fins ilustrativos, sem validar um campo térmico contínuo.

O enriquecimento das entradas com umidade relativa produziu uma redução pequena no MAE médio da regressão linear, com melhorias em cinco sensores-alvo e aumento do erro nos outros quatro. Dessa forma, não foi observada uma vantagem uniforme da inclusão dessa grandeza nas condições avaliadas. Os registros de energia, por sua vez, apresentaram baixa disponibilidade temporal, cobrindo apenas 4,07% da grade considerada, e não tiveram sua unidade física confirmada. Por esse motivo, sua utilização permaneceu restrita a uma análise exploratória.

As conclusões obtidas estão limitadas a um único ambiente, um período de observação e uma divisão cronológica de treinamento e teste, considerando apenas janelas com temperaturas disponíveis para todos os sensores do conjunto principal. Não foram avaliados cenários de indisponibilidade simultânea das entradas ou a estabilidade dos modelos em outras condições ambientais. Além disso, as medições dos próprios sensores foram utilizadas como referência, sem comparação com instrumentos calibrados. Portanto, os erros observados não demonstram exatidão metrológica nem validam diretamente a reconstrução de temperaturas em posições não instrumentadas ou a avaliação de conforto térmico.

Como continuidade, recomenda-se avaliar os métodos em outros períodos e ambientes, investigar estratégias de reconstrução diante de falhas dos sensores de referência e validar estimativas em posições não instrumentadas. A integração de novas fontes de dados, após a verificação de suas convenções temporais e unidades físicas, também poderá ampliar as possibilidades de análise. Por fim, a utilização das temperaturas reconstruídas em estudos de conforto térmico dependerá da definição de um protocolo específico e da obtenção das demais variáveis ambientais e pessoais necessárias.

Em síntese, os resultados demonstram que dados históricos de uma infraestrutura IoT existente podem ser utilizados para reconstruir temperaturas de sensores físicos com erros relativamente baixos nas condições experimentais avaliadas. A comparação entre métodos e configurações evidencia a importância de considerar as características de cada sensor-alvo e de selecionar adequadamente as informações utilizadas na reconstrução, oferecendo uma base experimental para futuras aplicações de sensoriamento virtual no LASDPC.

REFERÊNCIAS

ALLEGRO MICROSYSTEMS. **ACS712: Galvanically Isolated Linear Current Sensor IC**. [S.l.], s.d. Disponível em: <https://www.allegromicro.com/en/products/sense/current-sensor-ics/integrated-current-sensors/acs712>. Acesso em: 31 out. 2026. Citado na página 31.

ALSALEHY, A. S.; BAILEY, M. Improving time series data quality: Identifying outliers and handling missing values in a multilocation gas and weather dataset. **Smart Cities**, v. 8, n. 3, 2025. Artigo 82. Citado 2 vezes nas páginas 16 e 19.

ASHRAE. **Standard 55: Thermal Environmental Conditions for Human Occupancy**. s.d. Apresentação institucional da norma ANSI/ASHRAE Standard 55-2023. Disponível em: <https://www.ashrae.org/technical-resources/bookstore/standard-55-thermal-environmental-conditions-for-human-occupancy>. Acesso em: 31 out. 2026. Citado na página 18.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. Citado 2 vezes nas páginas 16 e 18.

BRUNELLO, A.; URGOLO, A.; PITTINO, F.; MONTVAY, A.; MONTANARI, A. Virtual sensing and sensors selection for efficient temperature monitoring in indoor environments. **Sensors**, v. 21, n. 8, 2021. Artigo 2728. Citado 5 vezes nas páginas 11, 17, 19, 20 e 43.

CHO, E.; CHANG, T.-W.; HWANG, G. Data preprocessing combination to improve the performance of quality classification in the manufacturing process. **Electronics**, v. 11, n. 3, 2022. Artigo 477. Citado na página 19.

GUANGZHOU AOSONG ELECTRONICS. **AM2302 Technical Manual**. [S.l.], s.d. Disponível em: <https://www.aosong.com/uploadfiles/2025/04/20250417105409216.pdf>. Acesso em: 31 out. 2026. Citado na página 31.

JEDERMANN, R.; PALAFOX-ALBARRáN, J.; ROBLA, J. I.; BARREIRO, P.; RUIZ-GARCíA, L.; LANG, W. Interpolation of spatial temperature profiles by sensor networks. In: **2011 IEEE SENSORS Proceedings**. Limerick, Ireland: IEEE, 2011. p. 778–781. Disponível em: <https://www.icia.uni-bremen.de/en/publications.html>. Acesso em: 30 out. 2026. Citado 2 vezes nas páginas 17 e 19.

MARQUES, L. de S.; TEIXEIRA, P. P.; SOARES, R. C. M.; TAVONI, F.; ALEXANDRE, V.; ESTRELLA, J. C. From deployment to operation: A reproducible IoT testbed for smart-building HVAC with OTA and observability. In: **2026 IEEE International Conference on Smart Internet of Things (SmartIoT)**. [S.l.]: IEEE, 2026. p. 393–399. Citado 3 vezes nas páginas 15, 18 e 25.

PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COURNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY Édouard. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12,

p. 2825–2830, 2011. Disponível em: <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 30 out. 2026. Citado 2 vezes nas páginas 16 e 28.

TAVONI, F.; CODORNIZ, A. V. V.; ESTRELLA, J. C.; MARQUES, L. de S.; MESSIAS, A. L. S. Modular digital twin architecture for smart building energy optimization: A open-source approach. In: **Proceedings of the 41st ACM/SIGAPP Symposium on Applied Computing**. New York, NY, USA: Association for Computing Machinery, 2026. 3 p. Evento realizado em Thessaloniki, Greece. Citado 2 vezes nas páginas 16 e 19.

YUAN, Q.; YAO, P.; ZHAO, W.; ZHANG, B. Optimization of sparse sensor layouts and data-driven reconstruction methods for steady-state and transient thermal field inverse problems. **Sensors**, v. 25, n. 16, 2025. Artigo 4984. Citado na página 19.